



Agnieszka Popiel

Aplikacja mobilna jako klasyfikator zmian
skórnych oparty na konwolucyjnej sieci neuro-
nowej

Mobile Application as a Skin Lesion Classifier
Based on a Convolutional Neural Network

Praca magisterska

Promotor: dr hab. inż. Jarogniew Rykowski, prof. UEP

Kierunek: Informatyka i ekonometria

Specjalność: Informatyka w gospodarce i administracji

Poznań 2026

Spis treści

1	Wstęp	1
2	Głębokie uczenie w diagnostyce dermatologicznej	3
2.1	Wpływ rozwoju sztucznej inteligencji na medycynę	3
2.2	Przegląd wstępnych metod diagnostycznych	6
2.3	Głębokie uczenie w dermatologii	9
2.3.1	Podstawy deep learning	9
2.3.2	Klasyfikacja binarna	13
2.3.3	Klasyfikacja wieloklasowa	14
2.3.4	Rozwiązania mobilne	16
2.4	Wyzwania związane z głębokim uczeniem w dziedzinie dermatologii . . .	17
2.4.1	Stronniczość i ograniczona reprezentatywność	17
2.4.2	Problemy z generalizacją	18
2.4.3	Brak wyjaśnialności modeli	18
2.4.4	Prywatność i bezpieczeństwo danych	18
2.4.5	Regulacje prawne i odpowiedzialność	19
2.4.6	Problemy społeczne	20
2.4.7	Wyzwania związane z aplikacjami mobilnymi	20
2.5	Podsumowanie	20
3	Propozycja systemu do diagnostyki zmian skórnych	22
3.1	Dostępne zbiory danych zmian skórnych	22
3.1.1	ISIC	22
3.1.2	HAM10000	22
3.1.3	BCN20000	24

3.1.4	DERM7PT	25
3.1.5	PAD-UFES-20	25
3.1.6	MED-NODE	26
3.1.7	PH2	26
3.1.8	Fitzpatrick17k	27
3.1.9	Dermofit	28
3.2	Dobór zbiorów i opis wybranych zmian skórnych	30
3.2.1	Rak podstawnocomórkowy - basal cell carcinoma	31
3.2.2	Rogowacenie słoneczne - actinic keratosis	31
3.2.3	Zmiana melanocytowa - nevus	32
3.2.4	Rogowacenie łojotokowe - seborrheic keratosis	32
3.2.5	Rak kolczystokomórkowy - squamous cell carcinoma	33
3.2.6	Czerniak - melanoma	34
3.3	Infrastruktura	35
3.4	Podsumowanie	37
4	Metodyka badania	38
4.1	Model sieci neuronowej	38
4.1.1	Obróbka danych	39
4.1.2	Przygotowanie do trenowania	40
4.1.3	Proces trenowania	43
4.2	Aplikacja mobilna	44
4.3	Wyniki modeli	47
4.3.1	Metryki	47
4.3.2	Wartości F1 dla poszczególnych klas	48
4.3.3	Podsumowanie wyników	50
4.4	Praktyczne zastosowanie aplikacji	51
4.5	Podsumowanie	53
5	Podsumowanie	54

Rozdział 1

Wstęp

Rosnące tempo postępów w obszarze sztucznej inteligencji skłania środowisko naukowe do intensywnego badania jej zastosowań w różnych obszarach medycyny, w szczególności w diagnostyce obrazowej. Algorytmy głębokiego uczenia są wykorzystywane do automatycznej analizy zdjęć rentgenowskich klatki piersiowej w celu wykrywania zmian nowotworowych oraz do oceny obrazów tomografii komputerowej pod kątem wczesnych objawów udaru (Karthik i in., 2020; Lee, Lee i Kwon, 2023; Sun, Zheng i Qian, 2016). Konwolucyjne sieci neuronowe wykazały znaczący potencjał w zakresie komputerowo wspomaganej diagnostyki, osiągając wysoką skuteczność w analizie obrazów medycznych. Modele te dorównują specjalistom lub nawet osiągają lepsze wyniki od nich w interpretacji wyników badań czynnościowych układu oddechowego oraz w rozpoznawaniu zmian skórnych na podstawie zdjęć klinicznych (Brinker i in., 2019; Topalovic i in., 2019). Motywacją niniejszej pracy jest pogłębienie wiedzy na temat możliwości wykorzystania konwolucyjnych sieci neuronowych w diagnostyce zmian skórnych oraz opracowanie prototypu mobilnego systemu umożliwiającego wstępną ocenę znamion. System ten ma na celu zarówno zwiększenie dostępności narzędzi diagnostycznych, jak i podniesienie świadomości pacjentów w zakresie monitorowania zdrowia skóry.

Celem pracy jest opracowanie prototypu systemu rozpoznawania zmian skórnych opartego na konwolucyjnych sieciach neuronowych, zdolnego do identyfikacji rodzaju zmiany skórnej uchwyconej na zdjęciu wykonanym aparatem telefonu przez użytkownika. Projektowana aplikacja powinna charakteryzować się wysoką wydajnością oraz umożliwiać inferencję w czasie rzeczywistym, tak aby użytkownik mógł szybko przeprowadzić wstępną analizę niepokojących zmian skórnych.

W ramach badań przedstawiono system klasyfikacji zmian skórnych wykorzystujący konwolucyjną sieć neuronową zaimplementowaną w postaci aplikacji mobilnej. Wykorzystano zbiór PAD-UFES-20, obejmujący zdjęcia wykonane aparatem telefonu komórkowego, na podstawie których dotrenowano siedem wybranych wersji architektury. Najlepszy model został następnie przekonwertowany do formatu mobilnego i poddany wstępnym badaniom empirycznym na rzeczywistych zdjęciach zmian skórnych.

Praca składa się z pięciu rozdziałów. Rozdział drugi przedstawia potencjał sztucznej inteligencji oraz urządzeń mobilnych w obszarze diagnostyki wspomaganej komputerowo, omawia dotychczasowe rozwiązania w tej dziedzinie oraz podstawy głębokiego uczenia i metody oceny skuteczności modeli. Uwzględniono również kluczowe wyzwania związane z wykorzystaniem AI w diagnostyce dermatologicznej. Rozdział trzeci opisuje dostępne zbiory danych dotyczące zmian skórnych oraz proces decyzyjny prowadzący do wyboru modelu wykorzystanego w systemie. Przedstawiono również charakterystykę zmian skórnych uwzględnionych w badaniu oraz teoretyczną infrastrukturę projektowanego systemu. W rozdziale czwartym zaprezentowano szczegółową metodykę badawczą, obejmującą przygotowanie danych, proces trenowania modeli oraz implementację aplikacji mobilnej na system Android, wraz z diagramem klas ilustrującym architekturę aplikacji i jej komunikację z modelem. Przeanalizowano wyniki uzyskane dla wszystkich trenowanych modeli, ich skuteczność w analizie poszczególnych kategorii zmian skórnych oraz rezultaty badań empirycznych przeprowadzonych na łagodnych zmianach skórnych.

Rozdział 2

Głębokie uczenie w diagnostyce dermatologicznej

2.1 Wpływ rozwoju sztucznej inteligencji na medycynę

Dynamiczny rozwój technologii w XXI wieku wraz z rosnącym zapotrzebowaniem pacjentów na efektywne rozwiązania w sektorze opieki zdrowotnej, istotnie wpłynął na transformację współczesnej medycyny w ostatnich latach (Chapman i in., [2015](#)). Takie innowacje, jak elektroniczna dokumentacja medyczna, telemedycyna oraz technologie przenośne znacznie usprawniły dostępność i wygodę świadczeń usług zdrowotnych, a przełomowe rozwiązania nanotechnologii i druku 3D zrewolucjonizowały dziedzinę implantologii i inżynierii tkankowej (Haleem i in., [2023](#); Mahara i in., [2023](#); Thacharodi i in., [2024](#)).

Szczególne znaczenie w współczesnej medycynie zyskały technologie oparte na sieciach neuronowych i sztucznej inteligencji, ponieważ umożliwiają one przetwarzanie i analizę dużych wolumenów danych klinicznych, często w czasie rzeczywistym. Narzędzia wykorzystujące sztuczną inteligencję w medycynie można podzielić na dwie kategorie - systemy wirtualne oraz fizyczne. Do wirtualnych zastosowań sztucznej inteligencji zalicza się narzędzia monitorujące zdrowie i analizujące dane, natomiast fizyczne zastosowania AI w medycynie obejmują roboty pomagające w rutynowych procedurach chirurgicznych, a także inteligentne protezy sterowane adaptacyjnie (Amisha i in., [2019](#); Nayak i Kumar Das, [2020](#)).

Wykorzystanie technologii opartych na sztucznej inteligencji jest spójne z paradygmatem P4, czyli medycyny personalizowanej, predyktywnej, prewencyjnej i partycypacyjnej, której celem jest umożliwienie kompleksowego podejścia do tematu zdrowia przez analizę rozległych zbiorów danych. W praktyce oznacza to odejście od reaktywnego modelu opieki zdrowotnej na rzecz modelu proaktywnego, skoncentrowanego na profilaktyce oraz wczesnym wykrywaniu potencjalnych chorób. Stan zdrowia pacjenta w medycynie 4P jest opisywany przez spersonalizowaną chmurę szczegółowych danych, takich jak pomiary biochemiczne, ocenę narażenia na czynniki ryzyka (np. stres, zanieczyszczenia) oraz dane genetyczne. Inteligentne technologie medyczne zwiększają autonomię oraz wygodę pacjenta jednocześnie zmniejszając biurokrację i koszty usług medycznych przez ograniczenie dokumentacji automatyzację procesów (Alonso, De La Torre Díez i Zapiraín, 2019; Briganti i Le Moine, 2020; Głos, 2017).

W ciągu ostatnich dekad urządzenia mobilne, w szczególności smartfony, stały się kluczowym elementem ekosystemu nowoczesnej medycyny cyfrowej. Ich rola jest szczególnie widoczna w kardiologii, gdzie algorytmy sztucznej inteligencji implementowane w przenośnych urządzeniach umożliwiają ciągłe monitorowanie parametrów fizjologicznych oraz rejestrację sygnału elektrokardiograficznego. Zdalne monitorowanie EKG z wykorzystaniem takich urządzeń, jak Fitbit czy Apple Watch 4 oraz aplikacji mobilnych, m.in. Kardia, pozwala na wczesne wykrywanie migotania przedsionków i wspiera zarówno pacjentów, jak i lekarzy w ocenie stanu zdrowia. Podobne rozwiązania znalazły zastosowanie w endokrynologii, gdzie systemy monitorujące poziom glukozy we krwi, zsynchronizowane ze smartfonem i oparte na analizie AI, umożliwiają stałą kontrolę cukrzycy (Amisha i in., 2019; Briganti i Le Moine, 2020; Halcox i in., 2017). W neurologii natomiast przenośne systemy oparte na sztucznej inteligencji pozwalają na wczesne wykrywanie napadów epilepsji (Briganti i Le Moine, 2020). Na tym tle szczególnie obiecująco przedstawia się potencjał smartfonów w dermatologii. Analiza dostępnych aplikacji mobilnych wskazuje na szeroką gamę narzędzi wspierających zarówno pacjentów, jak i lekarzy. Obejmują one między innymi samokontrolę zmian skórnych, przewodniki dotyczące chorób dermatologicznych oraz systemy teledermatologii. Zdecydowana większość tych rozwiązań jest kierowana bezpośrednio do pacjentów, co podkreśla rosnącą rolę urządzeń mobilnych w profilaktyce oraz we wczesnym wykrywaniu niepokojących zmian skórnych. W połączeniu z algorytmami sztucznej inteligencji urządzenia mobilne posiadają potencjał

do znaczącego zwiększenia dostępności opieki dermatologicznej, zwłaszcza w regionach o ograniczonym dostępie do specjalistów oraz do wspierania użytkowników w systematycznym monitorowaniu stanu zdrowia skóry (Brewer i in., 2013; Kong i in., 2021; Weingast i in., 2013).

Modele sztucznej inteligencji znajdują szerokie zastosowanie w diagnostyce, obejmującej między innymi takie techniki jak radiografia rentgenowska, rezonans magnetyczny, endoskopia, ultrasonografia oraz patologia cyfrowa. Podejście to jest określane mianem diagnostyki komputerowo wspomaganej - CADx, czyli *computer-aided diagnosis*. W pulmonologii sztuczna inteligencja jest wykorzystywana do interpretacji wyników badań czynnościowych płuc. Oprogramowanie implementujące AI, zwłaszcza z ekspertyzą pulmonologów, charakteryzuje się wyższą dokładnością diagnostyczną niż samodzielna analiza specjalistów (Das i in., 2023; Topalovic i in., 2019). Konwolucyjne sieci neuronowe (CNN), czyli modele głębokiego uczenia specjalizujące się w analizie obrazów, sprawdziły się w przypadku wykrywania zapalenia i raka płuc, wirusa COVID-19 oraz innych anomalii na zdjęciach rentgenowskich klatki piersiowej (Hussain i in., 2021; Ismael i Şengür, 2021; Lee, Lee i Kwon, 2023; Rajaraman, Candemir i in., 2018). W dziedzinie gastroenterologii wykorzystano CNN do przetwarzania obrazów z endoskopii i ultrasonografii w celu skutecznego wykrywania takich nieprawidłowości jak refluks żołądkowo-przełykowy i zanikowe zapalenie błony śluzowej żołądka (Briganti i Le Moine, 2020; Yang i Bang, 2019). CADx okazało się również skuteczną metodą w przypadku klasyfikacji komórek zarażonych malarią oraz rozpoznawania choroby zwyrodnieniowej stawu kolanowego (Al-rimy i in., 2023; Rajaraman, Antani i in., 2018). Liczne badania poświęcone zastosowaniu metod sztucznej inteligencji w medycznej diagnostyce obrazowej wskazują na wysoką skuteczność modeli głębokiego uczenia w zadaniach klasyfikacji binarnej oraz wieloklasowej, wykrywania obiektów na zdjęciach oraz ich segmentacji (Elyan i in., 2022). Wynika to z faktu, że systemy wizji komputerowej oparte na sieciach neuronowych uczą się bezpośrednio z obrazów, czego konsekwencją jest identyfikacja skomplikowanych wzorców i zależności często niezauważanych nawet przez doświadczonych lekarzy. Modele te funkcjonują jako systemy typu „black-box”, co pozwala im zakwalifikować subtelne przypadki chorób i wykryć je w wczesnym stadium, choć z drugiej strony uniemożliwia pełną weryfikację poprawności wyników przez człowieka (Richens i Buchard, 2021).

Szczególnie istotnym zastosowaniem wizji komputerowej w systemach *computer-aided diagnosis* stanowi dermatologia, której problematyki podjęto się w niniejszej pracy. W kolejnych podrozdziałach przeprowadzono analizę porównawczą dotychczasowych metod diagnostycznych w dermatologii z nowoczesnymi metodami diagnostyki z asystą komputerową, opartymi na algorytmach uczenia maszynowego.

2.2 Przegląd wstępnych metod diagnostycznych

Tradycyjnie wstępna diagnostyka w dermatologii obejmuje badanie dermoskopowe lub wideodermoskopowe, polegające na ocenie znamienia w około dziesięciokrotnym powiększeniu.

Tabela 2.1. Algorytm ABCD

Kryterium	Liczba punktów do przyznania	Waga
A - asymetria	0 - brak asymetrii w osi X i Y 1 - asymetria w jednej z osi 2 - asymetria w obu osiach	1,3
B - nieregularność granicy zmiany	0 - brak nagłych zakończeń zmiany 1 - nagłe zakończenie w jednym segmencie ... 8 - nagłe zakończenie w ośmiu segmentach	0,1
C - zróżnicowanie kolorów zmiany	1 - jeden kolor 2 - dwa kolory ... 6 - sześć kolorów	0,5
D - elementy strukturalne	1 - jeden element ... 5 - pięć elementów	0,5

Źródło: opracowanie własne na podstawie (Nachbar i in., 1994)

W 1994 roku Stolz wraz z współpracownikami zaproponował algorytm dermoskopowy ABCD (Tab. 2.1), opierający się na wielowymiarowej analizie następujących cech: asymetrii (A), nierównych i postrzępionych brzegów (B), zróżnicowania kolorów (C) oraz obecności zmian morfologicznych (D), takich jak kropki, smugi, kuleczki lub sieci pigmentowe. Według innych interpretacji kryterium „D” dotyczy średnicy zmiany przekraczającej 6 mm. Na podstawie sumy iloczynów stopnia spełnienia poszczególnych kryteriów ABCD oraz ich wag jest obliczany wskaźnik badania dermoskopowego TDS (Total Der-

matoscopy Score), stanowiący półilościową miarę znacząco poprawiającą skuteczność diagnostyczną, szczególnie w przypadku osób niebędących dermatologami, takich jak pacjenci. Znamiona o wartości TDS poniżej 4,75 są uznawane za łagodne, w przedziale 4,76-5,45 za podejrzane i wymagającej rutynowej kontroli dermoskopowej, a powyżej 5,45 za wysoce podejrzane w kierunku czerniaka (Nachbar i in., 1994; Rutkowski i in., 2016).

W 2004 roku rozszerzono tę zasadę o dodatkową cechę „E”, oznaczającą ewolucję rozmiaru, kształtu, koloru, powierzchni oraz innych objawów, co pozwala uwzględnić dynamiczny charakter nowotworu (Abbasi i in., 2004; Duarte i in., 2021). W literaturze przedstawiono również podobny algorytm CASH - kolor (C), architektura (A), symetria (S), homogeniczność (H) - który rozszerza ABCD o analizę wzorców oraz nie wymaga wag, przez co jest prostszy w użyciu (Henning i in., 2008). W diagnostyce potencjalnie złośliwych zmian skórnych jest również wykorzystywana zasada „brzydkiego kaczątka”, polegająca na identyfikacji znamion odbiegających wyglądem od innych typowo łagodnych zmian występujących u pacjenta. Znamiona znacząco różniące się od pozostałych uznaje się za potencjalnie złośliwe, ponieważ znamiona barwnikowe należy oceniać nie tylko na podstawie cech morfologicznych pojedynczej zmiany, ale także je rozpatrywać w kontekście pozostałych znamion pacjenta (Grob i Bonerandi, 1998; Kamińska-Winciorek i Śpiewak, 2011). Kolejną metodą wstępnej oceny złośliwości zmiany skórnej jest skala siedmiopunktowa (7PCL) opracowana w latach 80. XX wieku. Znamię klasyfikuje się jako podejrzane, jeżeli obecne są co najmniej trzy z danych cech: zmiana wielkości zmiany, nieregularna pigmentacja, nieregularne brzegi, stan zapalny, swędzenie, średnica większa niż 7 mm, sączenie i strupy. W 1989 udoskonalono metodę siedmiu punktów o wagi, które opracowano na podstawie częstotliwości występowania danych objawów w przypadku czerniaka złośliwego skóry. Dwa punkty są przyznawane dla zmiany wielkości, nieregularnej pigmentacji oraz nieregularnych brzegów, natomiast pozostałe cechy są oceniane na jeden punkt. Wynik większy lub równy trzy stanowi wskazanie do badania histopatologicznego (Congdon i Davis, 2023; MacKie, 1990; Mackie, 1989; Walter i in., 2013). Opracowano również algorytmy o podejściu krokowym, takie jak metoda Menziesa, metoda „chaosu i wzorów” oraz algorytm TADA. Metoda Menziesa jest szczególnie czuła w wykrywaniu czerniaka i składa się z dwóch etapów. Badanie wstępne polega na ocenie symetrii zmiany oraz jednorodności koloru - jeśli oba kryteria są spełnione, znamię jest


uznawane za łagodne. W przeciwnym razie analizuje się cechy typowe dla czerniaka, takie jak niebiesko-białawy welon, liczne brązowe lub niebiesko-szare kropki, pseudopodia i smugi promieniste, odbarwienia bliznopodobne, obwodowo ułożone czarne kropki lub grudki, pięć lub sześć kolorów oraz poszerzona siatka. Spełnienie któregokolwiek z tych kryteriów sugeruje wysokie prawdopodobieństwo czerniaka (Menzies i in., 1996). Metoda „chaosu i wzorów” opiera się na drzewie decyzyjnym badającym obecność „chaosu” w zmianie, czyli asymetrii struktury i koloru, a następnie analizowane są wzory charakterystyczne dla czerniaka i pozostałych złośliwych nowotworów (Rosendahl i in., 2012). Skala TADA definiuje algorytm triażowy, którego pierwszy etap polega na badaniu znamienia pod kątem trzech powszechnie występujących nowotworów łagodnych (włókniaka twardego, naczyniaka i rogowacenia łojotokowego). Jeżeli zmiana zostanie zakwalifikowana jako jeden z tych trzech nowotworów, powinna być rutynowo monitorowana, lecz jest wykluczona z dalszej oceny pod kątem złośliwości. W kolejnym kroku jest oceniana obecność nieuporządkowanego lub asymetrycznego rozmieszczenia kolorów i struktur - ich wystąpienie stanowi wskazanie do biopsji. Jeśli takie cechy nie są obecne, jest sprawdzane sześć dodatkowych cech powszechnie występujących w przypadku czerniaka oraz innych zmian nowotworowych (Rogers i in., 2017).

Badanie dermoskopowe stosowane w połączeniu z algorytmami diagnostycznymi oraz wywiadem z pacjentem, stanowi skuteczną metodę profilaktyki czerniaka ze względu na swoją szybkość, nieinwazyjność oraz możliwość ograniczenia konieczności wykonania biopsji skóry. Dokładność rozpoznań klinicznych dla zmian barwnikowych po zastosowaniu dermoskopii wzrasta o około 30% w porównaniu z badaniem okiem nieuzbrojonym. Należy jednak podkreślić, że algorytmy dermoskopowe wykazują ograniczoną skuteczność w przypadku wykrywania wczesnych czerniaków o średnicy poniżej 5 mm, czerniaków guzkowych i bezbarwnikowych oraz zmian w odrębnie owłosionej skórze głowy, dłoni i stóp, twarzy, błon śluzowych jamy ustnej i narządów płciowych (Davis i in., 2020; Kamińska-Winciorek i Śpiewak, 2011; Rutkowski i in., 2016; Sonthalia, Yumeen i Kaliyadan, 2025). Dermoskopię cechuje również wysoka zależność od doświadczenia specjalisty, ponieważ wymaga ona zarówno szkoleń jak i użycia metod klinicznych, rozumowania poznawczego, diagnostyki różnicowej i znajomości historii zdrowia pacjenta. Badanie dermoskopowe nie stanowi ostatecznej diagnozy i powinno być połączone z histopatologią, ponieważ umożliwia one jednoznaczne rozstrzygnięcie diagnostyki w przy-

padkach, w których jest widoczny wyraźny wzorec dermoskopowy (Sonthalia, Yumeen i Kaliyadan, 2025; Yélamos i in., 2019).

2.3 Głębokie uczenie w dermatologii

2.3.1 Podstawy deep learning




Rysunek 2.1. Relacje między sztuczną inteligencją, uczeniem maszynowym i głębokim uczeniem

Źródło: opracowanie własne

W 2000 roku opracowano pierwszy komputerowy system dermoskopii cyfrowej, klasyfikujący zmiany skórne na podstawie cech charakterystycznych czerniaka opisanych w metodzie ABCD i siedmiu punktów (Gutkowicz-Krusin i in., 2000). Wraz z dynamicznym rozwojem sztucznej inteligencji rozpoczęto badania nad jej zastosowaniem w medycynie, w tym w dermatologii (Goodfellow, Bengio i Courville, 2016). Sztuczna inteligencja (AI, ang. *artificial intelligence*) stanowi szeroką dziedzinę badań dotyczącą zdolności systemów komputerowych do symulowania procesów poznawczych. Uczenie maszynowe (ML, ang. *machine learning*) jest podzbiorem sztucznej inteligencji poświęconym algorytmom potrafiącym uczyć się z danych oraz identyfikować wzorce bez konieczności dostarczania instrukcji (Rys. 2.2). Głębokie uczenie (DL, ang. *deep learning*) to obszar uczenia maszynowego polegający na uczeniu głębokich sieci neuronowych, czyli sieci neuro-

nowych składających się z wielu warstw. *Deep learning* radzi sobie szczególnie dobrze z wykrywaniem złożonych struktur i zależności, osiągając przełomowe wyniki zarówno w zadaniach rozpoznawania obrazów i dźwięków jak i rozumienia języka naturalnego i tłumaczeniu (Goodfellow, Bengio i Courville, 2016; LeCun, Bengio i Hinton, 2015; Russell i Norvig, 2022).



Rysunek 2.2. Podstawowa architektura konwolucyjnej sieci neuronowej

Źródło: opracowanie własne na podstawie (Ghosh i in., 2020)

Sieci neuronowe (ANN, ang. *artificial neural network*) są definiowane jako systemy przetwarzania informacji inspirowane funkcjonowaniem układu nerwowego. W dziedzinie widzenia komputerowego (CV, *computer vision*) standardem stały się konwolucyjne sieci neuronowe (CNN, ang. *convolutional neural network*), których architektura jest inspirowana korą wzrokową (Ghosh i in., 2020; Hubel i Wiesel, 1968). Podstawy teoretyczne CNN zostały opracowane już w latach 60, lecz ich rozwój rozpoczął się dopiero w 2012 roku wraz z prezentacją architektury AlexNet (Hinton i in., 2012; Hubel i Wiesel, 1968). Tradycyjna konwolucyjna sieć neuronowa (Rys. 2.2) składa się z jednej lub wielu warstw konwolucyjnych oraz warstw łączenia (ang. *pooling*), po których następuje jedna lub wiele warstw w pełni połączonych (FC, ang. *fully connected*). Warstwa konwolucyjna składa się z kilku jąder konwolucyjnych które obliczają mapy cech danych wejściowych, jednocześnie ucząc się ich reprezentacji. Kolejne warstwy przetwarzają mapy cech z warstw poprzednich, stosując nieliniowe funkcje aktywacji i generując coraz bardziej abstrakcyjne uogólnienia obrazu. Warstwa pooling redukuje liczbę parametrów poprzez zagregowanie danych z poprzednich warstw, natomiast końcowa warstwa FC pełni funkcję klasyfikatora (Ghosh i in., 2020). W efekcie warstwy konwolucyjne najniższych poziomów wykrywają podstawowe cechy, natomiast wyższe warstwy identyfikują

bardziej złożone zależności. W przypadku dermoskopowego zdjęcia czerniaka najniższe warstwy przetwarzają podstawowe cechy, takie jak kolor, a kolejne analizują zależności między pojedynczymi pikselami, wykrywając cechy morfologiczne. Następnie warstwa *fully connected* przypisuje prawdopodobieństwo przynależności obrazu do jednej z klas (Ghosh i in., 2020).

W związku z opisanym mechanizmem wiele badaczy analizujących możliwości konwolucyjnych sieci neuronowych w dziedzinach medycznych decyduje się na zastosowanie uczenia transferowego (ang. *transfer learning*). Uczenie transferowe polega na wykorzystaniu wag wstępnie wyszkolonego modelu na dużym, ogólnym zbiorze danych w innym, bardziej wyspecjalizowanym zadaniu, często z mniejszym zbiorem danych. Najczęściej stosowane modele wstępnie wytrenowane to AlexNet, VGGNet, GoogLeNet, DenseNet, EfficientNet oraz ich liczne modele pochodne i mieszane. Technika *transfer learning* jest szeroko wykorzystywana w analizie obrazów medycznych oraz wykazuje się znacznie wyższymi wynikami niż sieci konwolucyjne budowane od zera do zadań medycznych (Ghosh i in., 2020; Kanavati i Tsuneki, 2021; Mahbod i in., 2020).

Wydajność modeli uczenia maszynowego jest mierzona za pomocą kilku podstawowym metryk. Dokładność (ang. *accuracy*) jest najprostszą miarą określającą zdolność modelu do dokonywania poprawnych przewidywań. Jest ona stosunkiem liczby poprawnych predykcji do całkowitej liczby przykładów w zbiorze testowym (Erickson i Kitamura, 2021; Grandini, Bagli i Visani, 2020; *Podstawy uczenia maszynowego*, 2022; Ratinio, Teuho i Klén, 2024). Dokładność można wyrazić następującym wzorem:

$$\text{accuracy} = \frac{TP + TN}{TP + FP + TN + FN} \quad (2.1)$$

gdzie:

- TP - liczba prawdziwie pozytywnych klasyfikacji,
- TN - liczba prawdziwie negatywnych klasyfikacji,
- FP - liczba fałszywie pozytywnych klasyfikacji,
- FN - liczba fałszywie negatywnych klasyfikacji.

Dokładność nie jest optymalną metryką szczególnie w przypadku zbiorów danych, w których liczebności klas nie są równe. Jeżeli jedna klasa ma znacznie większą liczebność, model może osiągać wysoką dokładność, jednocześnie ignorując rzadkie, lecz kluczowe

klinicznie przypadki, takie jak zmiany złośliwe (Grandini, Bagli i Visani, 2020; *Podstawy uczenia maszynowego*, 2022).

Pełność (ang. *recall*), w medycynie określana czułością (ang. *sensitivity*) mierzy stosunek prawidłowo zakwalifikowanych pozytywnych przypadków. Wysoka pełność oznacza, że model wykrywa większość pozytywnych próbek. W diagnostyce medycznej czułość jest szczególnie istotna, ponieważ pominięcie przypadku pozytywnego oznacza niewykrycie choroby (*Podstawy uczenia maszynowego*, 2022; Rainio, Teuho i Klén, 2024).

$$\text{recall} = \frac{TP}{TP + FN} \quad (2.2)$$

Precyzja (ang. *precision*) określa odsetek prawidłowo sklasyfikowanych pozytywnych przypadków wśród wszystkich predykcji pozytywnych. Wysoka precyzja oznacza, że model ma niską tendencję do klasyfikowania negatywnych przypadków jako pozytywne. Metryka ta jest szczególnie istotna w sytuacjach, w których pomyłki wiążą się z wysokim kosztem (Erickson i Kitamura, 2021; *Podstawy uczenia maszynowego*, 2022; Rainio, Teuho i Klén, 2024).

$$\text{precision} = \frac{TP}{TP + FP} \quad (2.3)$$

Zwiększenie precyzji może odbyć się wyłącznie kosztem zmniejszenia pełności, a wzrost pełności spowoduje spadek precyzji, wobec czego jest konieczne znalezienie kompromisu między nimi bądź priorytetyzacja jednej z metryk. W diagnostyce czerniaka złośliwego kluczowa jest pełność, ponieważ koszt konsultacji lub biopsji jest niewielki w porównaniu z ryzykiem przeoczenia zmiany złośliwej (Grandini, Bagli i Visani, 2020; *Podstawy uczenia maszynowego*, 2022; Rainio, Teuho i Klén, 2024).

W badaniach medycznych często stosuje się również swoistość (ang. *specificity*), definiowaną jako odsetek prawidłowo rozpoznanych przypadków negatywnych. Swoistość odzwierciedla zdolność modelu do unikania „fałszywych alarmów” (Rainio, Teuho i Klén, 2024).

$$\text{specificity} = \frac{TN}{TN + FP} \quad (2.4)$$

Wynik F1 stanowi średnią harmoniczną z precyzji i pełności. Jest szczególnie przydatny w przypadku niezbalansowanych zbiorów, ponieważ odzwierciedla kompromis

między obiema miarami (Erickson i Kitamura, 2021; *Podstawy uczenia maszynowego*, 2022; Rainio, Teuvo i Klén, 2024).

$$F1\ Score = \frac{2TP}{2TP + FN + FP} \quad (2.5)$$

Krzywa charakterystyki operacyjnej odbiornika (ang. *Receiver Operating Characteristic Curve*) przedstawia zależność między odsetkiem prawdziwie pozytywnych i fałszywie pozytywnych klasyfikacji. AUC (ang. *Area Under the Curve*) określa obszar pod krzywą ROC i stanowi miarę jakości klasyfikatora. Wartość AUC równa 0,5 oznacza model działający na poziomie losowego klasyfikatora, 1 świadczy o perfekcyjnym modelu (Erickson i Kitamura, 2021).

W przypadku analizy obejmującej więcej niż dwie klasy, wartości metryk podlegają agregacji na poziomie wszystkich klas. W tym celu stosuje się średnią arytmetyczną (ang. *macro*) lub średnią ważoną (ang. *weighted*). Alternatywnym podejściem jest globalne zliczanie poprawnych i niepoprawnych predykcji (ang. *micro*) albo uśrednienie wyników metryk dla wszystkich próbek (ang. *samples*) (*Podstawy uczenia maszynowego*, 2022).

2.3.2 Klasyfikacja binarna

Bassel i in. (2022) opracowali metodę agregującą wyniki wielu modeli w celu klasyfikacji nowotworów skóry jako złośliwe lub łagodne. Zbiór danych obejmował 1.000 obrazów czerniaka i 1.000 zdjęć nowotworów łagodnych pochodzących z archiwów ISIC. W badaniu wykorzystano maszynę wektorów nośnych, lasy losowe oraz metodę k-najbliższych sąsiadów, a także głębokie sieci neuronowe takie jak Xception, ResNet50 oraz VGG16. Metoda osiągnęła dokładność 90,9%, wynik F1 równy 89,6%, czułość 88,6% oraz AUC 91,7%.

W 2019 Adegun i Viriri (2020) przedstawili system oparty na głębokich sieciach neuronowych rozróżniający czerniaka od pozostałych zmian skórnych. Model trenowano na zbiorach zdjęć dermoskopowych ISIC 2017 oraz PH2, łącznie obejmujących 2.200 obrazów w zbiorze treningowym i 660 w testowym. Autorzy zaproponowali własną architekturę konwolucyjnej sieci neuronowej typu koder-dekoder oraz zastosowali techniki augmentacji obrazu, takie jak losowe obroty. Metoda osiągnęła dokładność 95%, czułość 97% i swoistość 96%.

Alzubaidi i in. (2021) zaproponowali rozwiązanie oparte na głębokich konwolucyjnych sieciach neuronowych, wykorzystujące zbiory ISIC z konkursów z lat 2016-2020, 170 obrazów z zbioru MED-NODE oraz 1.300 zdjęć z zbioru Dermofit. Zastosowali augmentację danych zwiększającą liczbę przykładów do 200 000 oraz techniki *transfer learning* i *double transfer learning*. W badaniu uzyskano dokładność wynoszącą 98,57%, pełność 97,9%, precyzję 99,18% oraz F1 równe 98,53%.

Jojoa Acosta i in. (2021) przedstawili architekturę składającą się z dwóch konwolucyjnych sieciach neuronowych. Pierwsza generowała maskę obszaru istotnego (ang. *region of interest*), natomiast druga była oparta na architekturze ResNet152 i klasyfikowała zmiany jako łagodne i złośliwe. Wykorzystano dane z konkursu ISIC z 2017 roku oraz dodatkowo dane ze zbioru PH2, zastosowano technikę *downsampling* dla klasy łagodnej, czyli zmniejszono liczbę przykładów z tej klasy, oraz technikę augmentacji danych. Najlepszy model osiągnął czułość 82%, swoistość 92,5%, dokładność 90,4%.

Menegola i in. (2017) przeanalizowali działanie głębokich sieci neuronowych w połączeniu z różnymi metodami *transfer learning*. Autorzy wykorzystali zbiór Interactive Atlas of Dermoscopy oraz dane z konkursu ISIC 2017. Przetestowano modele ImageNet, VGG-M i VGG-16, wykazując, że *fine-tuning* znacząco poprawia wyniki klasyfikację, a *transfer learning* jest najbardziej efektywny w przypadku modeli uczonych na danych o wysokim stopniu ogólności, takich jak ImageNet.

2.3.3 Klasyfikacja wieloklasowa

Alwakid i in. (2022) przedstawili trzy etapową technikę polegającą na wstępnym poprawieniu jakości obrazu, segmentacji obszaru istotnego a następnie analizy przez zmodyfikowany model ResNet-50. Autorzy wykorzystali zbiór HAM10000 opublikowany przez International Skin Imaging Collaboration, który obejmuje siedem klas: raka podstawnokomórkowego, czerniaka złośliwego, włókniaka twardego, łagodne rogowacenie, zmiany naczyniowe oraz melanocytowe. Opracowana metoda osiągnęła dokładność 86%, precyzję 84%, pełność 86% oraz F1 na poziomie 86%, znacznie przewyższając wyniki wcześniejszych badań.

Mahbod i in. (2020) zbadali wpływ kadrowania obrazów zmian skórnych oraz zastosowania uczenia transferowego na modelach EfficientNetB0, EfficientNetB1 i SeResNeXt-50. Autorzy zaproponowali podejście polegające na łączeniu wyników kliku

modeli w jeden system decyzyjny, osiągając rezultaty porównywalne z ówczesnie najlepszymi wynikami modeli w rankingu ISIC dla konkursu z 2018 roku, z którego uzyskano dane.

W 2022 roku Lu i Firoozeh Abolhasani Zadeh (2022) przedstawili usprawniony model oparty na głębokiej sieci neuronowej XceptionNet. Dodatkowo zastosowali funkcje aktywację Swish oraz augmentację obrazów. Model wytrenowano na podstawie danych z zbioru HAM10000. Metoda osiągnęła dokładność 100%, czułość 94,05%, precyzję 97,07% oraz wynik F1 95.53%.

Hosseinzadeh Kassani i Hosseinzadeh Kassani (2019) porównali popularne głębokie konwolucyjne sieci neuronowe Xception, AlexNet, VGGNet oraz ResNet w zadaniu klasyfikacji wieloklasowej zmian skórnych. Wykorzystano zbiór ISIC 2018, który obejmuje 10.015 zdjęć dermoskopowych i siedem kategorii zmian skórnych. Najlepsze wyniki osiągnął model ResNet50 z dokładnością wynoszącą 92,08%, F1 92,74%, precyzją 93,73% i pełnością 92,53%.

Han i in. (2018) dokonali *fine-tuning* na konwolucyjnej sieci neuronowej ResNet-152 w celu klasyfikacji 12 kategorii zmian skórnych - raka podstawnomórkowego, płaskonabłonkowego i śródnabłonkowego, czerniaka złośliwego, rogowacenia słonecznego i łojotokowego, plam soczewicowatych, włókniaka twardego, ziarniniaka ropnego, naczyńniaka, brodawki i znamienia melanocytowego, potocznie nazywanego pieprzykiem. *Fine-tuning* obejmował 19.398 obrazów z zbiorów MED-NODE, Dermofit oraz zdjęć z Uniwersytetów Asan i Hallym oraz obrazów pobranych z różnych internetowych atlasów dermatologicznych. Model osiągnął wyniki porównywalne do 16 dermatologów.

Kawahara, Bentaieb i Hamarneh (2016) w 2016 roku zaprezentowali klasyfikator liniowy wytrenowany na podstawie cech wyodrębnionych z głębokiej sieci konwolucyjnej. Model został wyuczony na zbiorze danych Dermofit i rozróżniał dziesięć kategorii zmian skórnych z większą dokładnością niż ówczesne wyniki innych metod dla tego samego zbioru danych.

Esteva i in. (2017) wytrenowali konwolucyjną sieć neuronową GoogleNetInceptionV3 na 129.450 przykładach obejmujących 2.032 jednostki chorobowe i porównali jej wydajność z 21 dermatologami. Szczególnie skupiono się na rozróżnianiu nowotworów keratynocytowych (rak podstawnomórkowy i płaskonabłonkowy) od łagodnych rogowaceń oraz rozróżnianiu czerniaków złośliwych i znamion melanocytowych. Sieć

wykazała się skutecznością na poziomie porównywalnym z dermatologami. Autorzy zasugerowali wykorzystanie tego typu rozwiązań do zapewnienia powszechnego dostępu do opieki diagnostycznej po niższych kosztach za pomocą urządzeń mobilnych.

2.3.4 Rozwiązania mobilne

W 2019 of Computer Science i in. (2020) przedstawili aplikację mobilną dla systemu Android klasyfikującą zmiany skórne na łagodne i złośliwe. Autorzy zastosowali własny, trzy warstwowy model konwolucyjnej sieci neuronowej, VGG-16 oraz Google Inception V3. Model Inception V3 osiągnął dokładność 81% i czułość 84%. Dane uzyskano z archiwów ISIC a do trenowania wykorzystano 1.758 obrazów poddanych technice augmentacji danych. Wytrenowany model Google Inception V3 przekonwertowano na model Tensorflow a następnie zaimportowano do aplikacji androidowej z prostym interfejsem użytkownika.

W aplikacji przedstawionej przez Wibowo, Adhi Hartanto i Wisnu Wirawan (2020) wykorzystano model MobileNet v2, cechujący się niewielkim rozmiarem oraz niskim opóźnieniem, zaprojektowany w celu użycia na systemach mobilnych. Zebrano 640 obrazów z oficjalnej strony International Skin Imaging Collaboration i podzielono na zbiór treningowy, testowy oraz walidacyjny. Skupiono się na dwóch rodzajach zmian skórnych - czerniaku złośliwym oraz rogowaceniu słonecznym, które może się przekształcić w raka płaskonabłonkowego. Wykorzystano technikę *region of interest*. Model przetestowano na fizycznie wydrukowanych zdjęciach zmian skórnych, na zdjęciach na komputerze z dziesięcio-centrymetrowym oddaleniem od kamery oraz na faktycznych zdjęciach skóry z czterokrotnym powiększeniem. Model uzyskał 70% dokładność w zadaniu klasyfikacyjnym ze zdjęć kamerą telefonu i 90% dokładności z zdjęciami ze zbioru.

Kousis i in. (2022) zbadali możliwości jedenastu konwolucyjnych sieci neuronowych w zadaniu klasyfikacji siedmiu zmian skórnych. Dane uzyskano z zbioru HAM10000, który obejmuje 10.000 obrazów zmian skórnych. Najlepsze wyniki osiągnął model DenseNet169 z dokładnością 92,25% i pełnością 93,59%. Autorzy wykorzystali uczenie transferowe oraz augmentację zdjęć. Model przekonwertowano do formatu tensorlite i utworzono aplikację mobilną android, która zbiera również informacje o ekspozycji na UV oraz lokalizacji użytkownika.

Bourouis i in. (2013b) opracowali prototyp mobilnego systemu do analizy zmian skórnych, wykorzystującego aparat smartfonu oraz lokalnie działającą sieć neuronową. Model został wytrenowany na zbiorze 200 obrazów w zadaniu binarnej klasyfikacji zmian skórnych na łagodne i złośliwe.

Dai i in. (2019) przedstawili aplikację mobilną przeznaczoną dla systemu iOS, wykorzystującą autorską sieć konwolucyjną wytrenowaną na podstawie 10.015 obrazów z zbioru HAM10000. Model został następnie przekonwertowany na format mobilny za pomocą biblioteki Core ML, co umożliwiło dokonanie predykcji w czasie niemal rzeczywistym. Po zrobieniu zdjęcia przez użytkownika aplikacja prezentuje na ekranie telefonu najbardziej prawdopodobną klasę zmiany skórnej. Autorzy nie opublikowali szczegółowych wyników walidacji ani metryk oceniających skuteczność modelu.

Kong i in. (2021) przeprowadzili analizę aplikacji wykrywających raka skóry dostępnych dla konsumentów przez platformy dystrybucji aplikacji mobilnych takie jak Google Play (aplikacje na systemy Android) oraz App Store (aplikacje na systemy iOS).

2.4 Wyzwania związane z głębokim uczeniem w dziedzinie dermatologii

Wprowadzanie systemów opartych na głębokim uczeniu do praktyki klinicznej, szczególnie do diagnostyki dermatologicznej, wiąże się z szeregiem wyzwań technicznych, etycznych, regulacyjnych i społecznych. Poniżej przedstawiono najważniejsze ograniczenia i problemy, z którymi wiąże się wdrażanie rozwiązań AI w dermatologii.

2.4.1 Stronniczość i ograniczona reprezentatywność

Kluczowym problemem modeli identyfikujących zmiany skórne jest ich stronniczość. Wynika ona z struktury i jakości dostępnych danych treningowych - większość z nich obejmuje głównie obrazy pacjentów o jasnym fototypie skóry, co obniża skuteczność modeli w przypadku osób o ciemniejszej karnacji. Badania wykazały, że sztuczna inteligencja pogłębia uprzedzenia uwzględnione w danych, co jest szczególnie niebezpieczne w dermatologii, ponieważ pacjenci o ciemniejszej skórze mają statystycznie niższe wskaźniki przeżycia w przypadku nowotworów skóry (Ward-Peterson i in., 2016). W

odpowiedzi na ten problem powstały takie zbiory jak Fitzpatrick17k, obejmujące szerokie spektrum fototypów skóry, jednak wykorzystanie zdjęć z atlasów zamiast obrazów dermoskopowych znacząco ogranicza ich przydatność (Groh i in., 2021).

2.4.2 Problemy z generalizacją

Niektóre modele głębokiego nauczania mogą wykazywać słabą zdolność generalizacji, działając dobrze wyłącznie na danych pochodzących z zbioru treningowego i walidacyjnego. W praktyce klinicznej zdjęcia zmian skórnych mogą być wykonywane różnymi urządzeniami w różnych warunkach, co może obniżyć skuteczność algorytmu (Kelly i in., 2019). Dodatkowo modele mogą uczyć się cech nieistotnych klinicznie, takich jak włosy lub odbicia światła. W jednym badaniu wykazano, że sztuczna inteligencja traktowała obecność linijki na zdjęciach dermoskopowych jako cechę wskazującą na nowotwór, ponieważ lekarze częściej mierzyli zmiany podejrzane o złośliwość (Esteva i in., 2017). Wiele modeli klasyfikacji zmian skórnych nie uwzględnia istotnych czynników klinicznych, takich jak wiek pacjenta, ekspozycja na promieniowanie UV czy historia nowotworów skóry w rodzinie. Ponadto, obecnie sztuczna inteligencja nie jest w stanie zastosować metody „brzydkiego kaczątka”, ponieważ algorytmy nie potrafią jeszcze porównywać wielu znamion u jednego pacjenta, aby określić, które z nich odbiega od jego fenotypu znamionowego.

2.4.3 Brak wyjaśnialności modeli

Modele głębokiego uczenia działają na zasadzie „czarnej skrzynki”, co utrudnia w wielu przypadkach uzasadnienie decyzji podjętych przez model. W medycynie jest kluczowe zrozumienie oraz weryfikacja diagnozy, dlatego tworzenie wyjaśnialnej sztucznej inteligencji (XAI, ang. *Explainable Artificial Intelligence*) stanowi poważne wyzwanie w wdrażaniu głębokiego uczenia (Ali i in., 2023; J. He i in., 2019; Kelly i in., 2019).

2.4.4 Prywatność i bezpieczeństwo danych

Skuteczne modele głębokiego uczenia wymagają dużych, wolnych od uprzedzeń i dobrze opisanych zbiorów danych. Ich pozyskiwanie wiąże się jednak z koniecznością ich anonimizacji oraz uzyskania zgody od pacjentów. Dane powinny być przechowywane i

wykorzystywane z zachowaniem wysokiego stopnia cyberbezpieczeństwa oraz zgodnie z regulacjami prawnymi dotyczącymi ochrony danych (Farhud i Zokaei, 2021; J. He i in., 2019). Integracja danych medycznych jest dodatkowo utrudniona przez brak standaryzacji. J. He i in. (2019) wskazują na potrzebę utworzenia globalnych standardów archiwizacji danych medycznych, analogicznych do standardów obrazowania DICOM (ang. *Digital Imaging and Communications in Medicine*).

2.4.5 Regulacje prawne i odpowiedzialność

Kluczowym krokiem we wprowadzaniu bezpiecznych i efektywnych algorytmów uczenia maszynowego do praktyki medycznej są odpowiednie regulacje i rygorystyczna kontrola jakości (J. He i in., 2019; Kelly i in., 2019). W Unii Europejskiej szczególne znaczenie ma Ogólne Rozporządzenie o Ochronie Danych oraz rozporządzenie o sztucznej inteligencji „AI Act” („Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO)”, 2016; „Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji)”, 2024). Zgodnie z art. 22 RODO każda osoba ma prawo nie podlegać decyzjom podejmowanym wyłącznie automatycznie oraz ma prawo wymagać wyjaśnienia decyzji podjętych przez algorytm, co na obecnym etapie rozwoju technologii AI jest często niemożliwe (J. He i in., 2019; „Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO)”, 2016). Rozporządzenie AI Act ma na celu zdefiniowanie sztucznej inteligencji oraz ustanowienie ram prawnych dotyczących tworzenia usług i produktów opartych na AI. Systemy medyczne wykorzystujące sztuczną inteligencję w większości należą do kategorii wysokiego ryzyka, co wiąże się z koniecznością spełnienia wymogów dotyczących zarządzania ryzykiem, jakości danych, nadzoru ludzkiego oraz cyberbezpieczeństwa („Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji)”, 2024; Van Kolschooten i Van Oirschot, 2024).

2.4.6 Problemy społeczne

Wdrożenie AI w medycynie wymaga odpowiedniego wyszkolenia kadry medycznej. Lekarze powinni znać zarówno możliwości jak i ograniczenia technologii głębokiego uczenia, aby móc z niej bezpiecznie korzystać. Badania wykazują, że pacjenci i lekarze obawiają się, że adaptacja sztucznej inteligencji w opiece medycznej będzie skutkować depersonalizacją medycyny i ograniczeniem roli lekarza w procesie diagnostycznym (Tang, Li i Fantus, [2023](#)).

2.4.7 Wyzwania związane z aplikacjami mobilnymi

W przypadku aplikacji mobilnych dodatkowym problemem jest jakość zdjęć wykonywanych przez użytkowników. Rozmazanie, niewłaściwe oświetlenie lub zbyt małe powiększenie mogą znacząco obniżyć skuteczność modelu i prowadzić do błędnych wyników.

2.5 Podsumowanie

Rozwój sztucznej inteligencji oraz powszechne stosowanie smartfonów otwierają szansę na transformację diagnostyki i leczenia chorób. Systemy oparte na sieciach neuronowych osiągnęły dojrzałość technologiczną i stały się bardziej niezawodne, często osiągając wyniki porównywalne i lepsze od specjalistów, dzięki czemu część z nich znalazła już zastosowanie w praktyce klinicznej (Li i in., [2022](#)). Na obecnym etapie rozwoju głębokie uczenie posiada ogromny potencjał w diagnostyce obrazowej i potrafi wykrywać subtelne sygnały niewidoczne dla człowieka. Należy jednak podkreślić, że sztuczna inteligencja powinna pełnić funkcję asysty dla lekarzy przez ich odciążenie, redukcję błędów oraz standaryzację decyzji, a nie ich zastępowanie. Chociaż wiele badań porównuje skuteczność algorytmów uczenia maszynowego ze skutecznością lekarzy, najlepsze rezultaty osiąga się w modelu współpracy, w którym lekarze korzystają z inteligentnych narzędzi jako elementu uzupełniającego proces diagnostyczny (Kelly i in., [2019](#)). Z tego względu wprowadzanie AI do praktyki klinicznej powinno odbywać się wyłącznie pod nadzorem specjalistów, tak aby technologia stanowiła realną pomoc zarówno dla lekarzy, jak i pacjentów (Kelly i in., [2019](#); Naeem i in., [2020](#)).

Aby było możliwe przełożenie wyników badań na skuteczne wdrożenia kliniczne, konieczne są dalsze prace nad następującymi aspektami modeli głębokiego uczenia:

- interpretowalność modeli - zwiększenie możliwości wyjaśniania decyzji podejmowanych przez sztuczną inteligencję oraz eliminacja czynników zakłócających proces uczenia,
- rozwój regulacji prawnych - dostosowanie przepisów do specyfiki systemów AI stosowanych w medycynie,
- definicja ram etycznych - określenie odpowiedzialności za decyzje oraz roli lekarza i sztucznej inteligencji w procesie leczenia,
- tworzenie niezależnych i reprezentatywnych zbiorów danych - obecne zbiory są ograniczone i stronnicze, szczególnie pod względem płci, fototypów skóry oraz wieku pacjentów,
- poufność danych - zapewnienie bezpiecznej integracji zanonimizowanych danych pochodzących z wielu źródeł.

W wyniku powszechności urządzeń mobilnych medycyna stopniowo przenosi się do wymiaru cyfrowego i internetowego. Integracja usług zdrowotnych z aplikacjami mobilnymi może znacząco zwiększyć dostępność opieki, poprawić profilaktykę oraz umożliwić pacjentom bardziej świadome zarządzanie własnym zdrowiem. Rozwijanie narzędzi łączących algorytmy diagnostyczne z intuicyjnymi interfejsami mobilnymi stanowi naturalny kierunek rozwoju współczesnej medycyny cyfrowej (Bourouis i in., 2013a; Brewer i in., 2013; of Computer Science i in., 2020). W niniejszej pracy przedstawiono propozycję systemu integrującego możliwości głębokich sieci neuronowych w diagnostyce zmian skórnych z aplikacją mobilną przeznaczoną dla systemu Android, co stanowi przykład praktycznego wykorzystania głębokiego uczenia w nowoczesnej opiece zdrowotnej. Architektura i działanie tej aplikacji zostaną przedstawione w następnym rozdziale.

Rozdział 3

Propozycja systemu do diagnostyki zmian skórnych

3.1 Dostępne zbiory danych zmian skórnych

3.1.1 ISIC

Do rozwoju metod sztucznej inteligencji w dermatologii w istotny sposób przyczyniła się organizacja International Skin Imaging Collaboration (ISIC), której celem jest zwiększenie skuteczności wczesnego wykrywania czerniaka i tym samym zmniejszenie śmiertelności związanej z nowotworami skóry. Od 2016 roku ISIC udostępnia obszerne zbiory obrazów z badań dermoskopowych wraz z danymi klinicznymi i wynikami diagnoz, organizując coroczne konkursy mające na celu doskonalenie algorytmów wizji komputerowej. Archiwa ISIC z lat 2016-2024 odegrały kluczową rolę w rozwoju badań nad wykorzystaniem sztucznej inteligencji w diagnostyce nowotworów skóry, a opracowane przez organizację standardy są powszechnie akceptowane w dziedzinie CADx. Zbiory z konkursów ISIC obejmują głównie obrazy dermoskopowe czerniaków i znamion melanocytowych, jednak w internetowych archiwach dostępne są również fotografie wielu innych rodzajów zmian skórnych (Li i in., [2022](#)).

3.1.2 HAM10000

HAM10000 stanowi jeden z najczęściej wykorzystywanych oficjalnych zbiorów International Skin Imaging Collaboration (Li i in., [2022](#)). Został opracowany w celu zgromadzenia

reprezentatywnej kolekcji najważniejszych kategorii diagnostycznych zmian barwnikowych, ponieważ wcześniejsze zasoby, takie jak archiwa ISIC czy zbiór PH2, były znacznie mniejsze i koncentrowały się głównie na diagnozie czerniaka złośliwego. HAM10000 obejmuje 10.015 obrazów dermoskopowych, z czego diagnoza ponad połowy została potwierdzona badaniem histopatologicznym. Zbiór uwzględnia również dane kliniczne pacjentów takie jak wiek, płeć oraz lokalizacja zmiany. Obrazy zbierano na przestrzeni 20 lat w dwóch ośrodkach - w klinice dermatologicznej Uniwersytetu Medycznego w Wiedniu oraz w gabinecie dermatologicznym Clifffa Rosendahla w Queensland. Austriacka część zbioru obejmuje zmiany u pacjentów często charakteryzujących się dużą liczbą znamion lub z znamionami podejrzanymi w kierunku czerniaka. Z kolei australijski zestaw danych pochodzi od pacjentów zamieszkujących region o wysokiej zapadalności na nowotwory skóry, u których często obserwuje się przewlekłe uszkodzenia skóry spowodowane intensywną ekspozycją na promieniowanie słoneczne, takie jak plamy soczewicowate.

Wyróżniono następujące klasy w zbiorze:

- akiec (actinic keratosis),
- bcc (basal cell carcinoma),
- bkl (benign keratosis),
- df (dermatofibroma),
- nv (melanocytic nevi),
- mel (melanoma),
- vasc (vascular lesion).

Klasa „akiec” obejmuje rogowacenie słoneczne, raka śródnabłonkowego oraz chorobę Bowena, czyli nieinwazyjne nowotwory, które można leczyć miejscowo bez konieczności wykonywania zabiegów chirurgicznych. Pomimo nieinwazyjności tych nowotworów należy wziąć pod uwagę, że te zmiany mogą przekształcić się w inwazyjnego raka płaskonabłonkowego (ang. *squamous cell carcinoma*), nieuwzględnionego w zbiorze. „Bcc” dotyczy raka podstawnokomórkowego, czyli powszechną odmianę raka nabłonkowego skóry, który jest wysoko uleczalny, lecz w przypadku braku leczenia rozwija się destrukcyjnie. Kategoria „bkl” stanowi ogólną klasę obejmującą łagodne rogowacenia skóry, takie jak rogowacenie łojotokowe (ang. *seborrheic keratoses*) i plamki słoneczne oraz rogowacenie podobne do liszaju płaskiego. Zdecydowano się na zgrupowanie tych zmian razem ze względu na podobieństwo pod względem biologicznym. „Df” obejmuje

dermatofibromę, czyli włókniaka twardego. Jest ona łagodną zmianą skórną, najczęściej powstająca w wyniku reakcji zapalnej na uraz. Klasa nv to znamiona melanocytowe, powszechnie znane jako pieprzyki. Kategoria „mel” dotyczy czerniaka złośliwego wywodzącego się ze znamion melanocytowych. Znamiona mogą być zwiększać ryzyko rozprzestrzeniania się w organizmie poprzez przenikanie poniżej naskórka do skóry właściwej, co w dermatologii jest określane inwazyjnością. W zbiorze uwzględniono wszystkie odmiany czerniaka, ale wykluczono czerniaka bezbarwnikowego, pod paznokciowego, ocznego oraz błony śluzowej. „Vasc” dotyczy łagodnych znamion naczyniowych, takich jak naczyńki wiśniowe, ziarniniaki ropne oraz siniaki, które charakteryzują się czerwonym lub fioletowym kolorem. (Tschandl, Rosendahl i Kittler, 2018).

3.1.3 BCN20000

BCN20000 to oficjalny zbiór ISIC udostępniony w 2024 roku. Autorzy zebrali 18.946 obrazów dermoskopowych z kliniki w Barcelonie wykonanych w latach 2010-2016. Zbiór obejmuje osiem kluczowych kategorii diagnostycznych w dermatologii, skupiając się szczególnie na zmianach w trudnych do zdiagnozowania miejscach, takich jak paznokcie i błony śluzowe, które często są pomijane przez pozostałe zbiory. W BCN20000 uwzględniono również płeć i wiek pacjenta oraz położenie zmiany. Wyróżniono następujące klasy w zbiorze:

- ak (actinic keratosis),
- bcc (basal cell carcinoma),
- bkl (benign keratosis),
- df (dermatofibroma),
- scc (squamous cell carcinoma),
- nv (nevus),
- mel (melanoma),
- vasc (vascular lesion).

W porównaniu z zbiorem HAM10000, BCN20000 obejmuje więcej obrazów oraz dodatkowo uwzględnia raka kolczystokomórkowego (scc) (Hernández-Pérez i in., 2024).

3.1.4 DERM7PT

DERM7PT stanowi zbiór danych służący do oceny skuteczności diagnostyki komputerowej na podstawie siedmiopunktowej skali oceny zmian skórnych. Zbiór obejmuje 1.011 obrazów dermoskopowych, sklasyfikowanych w pięciu kategoriach oraz dwudziestu szczegółowych diagnozach:

- bcc - basal cell carcinoma,
- nev - blue nevus, clark nevus, combined nevus, congenital nevus, dermal nevus, recurrent nevus, reed or spitz nevus,
- mel - melanoma, melanoma in situ, melanoma < 0,76 mm, melanoma 0,76 to 1,5 mm, melanoma > 1,5 mm,
- misc - dermatofibroma, lentigo, melanosis, miscellaneous, vascular lesion,
- sk - seborrheic keratosis.

W obrębie klasy „nev” wyszczególniono liczne typy powszechnych zmian melanocytowych, takich jak znamię błękitne, Clarka, złożone, wrodzone, śródskórne, nawrotowe, Reeda oraz Spitz. Klasa „mel” obejmuje różne warianty czerniaka, w tym czerniaka in situ (nieinwazyjnego) i trzy podgrupy wydzielone na podstawie średnicy zmiany. Kategoria „misc” zawiera łagodne zmiany skórne, takie jak włókniak twardy, plamki słoneczne czy melanoza. Dodatkowo wyodrębniono osobne klasy dla rogowacenia łojotokowego (sk) oraz raka podstawnokomórkowego (bcc). Autorzy zbioru przypisali każdej zmianie cechy odpowiadające siedmiopunktowej skali, umożliwiając analizę zarówno klasyfikacyjną, jak i cechową (Kawahara i in., [2019](#)).

3.1.5 PAD-UFES-20

PAD-UFES-20 jest zbiorem obejmującym 2.298 przypadków zmian skórnych wykonanych kamerą smartfonu, co czyni go szczególnie istotnym w kontekście projektowania mobilnych systemów wspomagania diagnostyki dermatologicznej. 58% znamion z zbioru zostało poddanych biopsji. PAD-UFES-20 zawiera sześć kategorii zmian skórnych:

- bcc (basal cell carcinoma),
- scc (squamous cell carcinoma),
- ack (actinic keratosis),

- sek (seborrheic keratosis),
- mel (melanoma),
- nev (nevus).

W ramach klasy „scc”, czyli raka kolczystokomórkowego uwzględniono również chorobę Bowena, który jest nieinwazyjną postacią tego nowotworu. Zbiór obejmuje również szeroki zakres danych klinicznych pacjentów, takich jak informacje o paleniu, obecności bólu lub krwawienia zmiany, a także dane socjoekonomiczne, takie jak dostęp do bieżącej wody i kanalizacji. PAD-UFES-20 jest jedynym publicznie dostępnym zbiorem obrazów zmian skórnych wykonanych kamerą telefonu komórkowego, co wyraźnie odróżnia go od pozostałych zasobów wykorzystywanych w badaniach nad automatyczną analizą dermatoskopową (Pacheco i in., [2020](#)).

3.1.6 MED-NODE

MED-NODE to zbiór danych obejmujący 170 obrazów klinicznych przedstawiających zmiany melanocytowe, spośród których 70 przypadków stanowi czerniak złośliwych a 100 to łagodne zmiany melanocytowe, powszechnie nazywane pieprzykami. Zdjęcia zostały pozyskane w klinice dermatologii Uniwersytetu Medycznego w Groningen, przy użyciu aparatu cyfrowego (Giotis i in., [2015](#)).

3.1.7 PH2

PH2 jest zbiorem opublikowany w 2013 roku, obejmujący 200 obrazów dermoskopowych. 40 przypadków to potwierdzony histopatologicznie czerniak, pozostałe zdjęcia stanowią łagodne znamiona melanocytowe. W zbiorze zawarto również szczegółowe informacje kliniczne i dermoskopowe, w tym ocenę cech strukturalnych, diagnozę kliniczną i histologiczną. Ze względu na swoją kompletność i dostępność PH2 stanowił podstawowy zestaw referencyjny w badaniach nad algorytmami klasyfikacji zmian skórnych, zanim został zastąpiony przez bardziej obszerne zbiory, takie jak HAM10000 (Mendonca i in., [2013](#)).

3.1.8 Fitzpatrick17k

Fitzpatrick17k składa się z 16.577 obrazów klinicznych pochodzących z dwóch internetowych atlasów dermatologicznych - DermaAmin oraz Atlas Dermatologico. Każde zdjęcie oznaczono etykietami typu skóry według skali Fitzpatricka, klasyfikującej reaktywność skóry na promieniowanie słoneczne. W zbiorze uwzględniono 114 schorzeń skóry, przy czym liczba obrazów przypadających na jedną jednostkę chorobową wynosi od 53 do 653 przypadków. Główne kategorie schorzeń obecne w zbiorze to:

- inflammatory,
- malignant epidermal,
- genodermatoses,
- benign dermal,
- benign epidermal,
- malignant melanoma,
- benign melanocyte,
- malignant cutaneous lymphoma,
- malignant dermal.

Do kategorii chorób zapalnych należą takie jednostki chorobowe jak łuszczyca i trądzik. Klasa „malignant epidermal” zawiera złośliwe nowotwory naskórka, na przykład raka podstawnokomórkowego i rógowacenie słoneczne. Grupa genodermatoz uwzględnia choroby dziedziczne skóry, takie jak neurofibromatoza i zespół Ehlersa-Danlosa. W klasie „benign dermal” i „benign epidermal” zawarto łagodne zmiany skórne na poziomie naskórka i skóry właściwej, na przykład włókniaka twardego lub ziarniniaka naczyńniowego. Kategoria łagodnych znamion melanocytowych uwzględnia różne rodzaje pieprzyków. Kategoria „malignant dermal” obejmuje mięsaka Kaposiego, czyli nowotwór złośliwy wywołany przez wirusa HHV-8. Autorzy uwzględnili także osobną grupę dla czerniaka złośliwego, która zawiera przypadki nowotworu w różnych stadium choroby oraz dla ziarniniaka grzybiastego, czyli najpowszechniejszego chłoniaka skóry (Bowman, Hogan i Sannusi, 2001; Groh i in., 2021; Schneider i Dittmer, 2017).

Zbiór Fitzpatrick17k odpowiada na istotną lukę w dziedzinie diagnostyki komputerowej, dotyczącą niedostatecznej reprezentacji zróżnicowanych fototypów skóry w dostępnych danych. Co więcej, zbiór rozszerza badane jednostki z znamion do ogólnych

dermatologicznych schorzeń, takich jak choroby autoimmunologiczne lub urazy. Jednocześnie zbiór jest ograniczony przez brak jednolitej obróbki obrazów, ponieważ zdjęcia są wykonane w różnych warunkach, co skutkuje zmiennością jakości, co nie jest odpowiednimi warunkami do trenowania modeli uczenia maszynowego. Dodatkowy problem stanowi brak publicznie dostępnego archiwum obrazów. Udostępniono jedynie odnośniki do atlasów internetowych, co powoduje ryzyko utraty danych w przypadku usunięcia materiałów źródłowych (Groh i in., 2021).

3.1.9 Dermofit

Dermofit to niepubliczny zbiór opracowany przez Uniwersytet Edynburski, obejmujący 1300 obrazów klinicznych sklasyfikowanych w dziesięciu kategoriach zmian skórnych. Diagnozy zostały potwierdzone przez dermatologów i dermopatologów. Do każdego obrazu załączono również maskę segmentacyjną, wyznaczającą obszar zmiany. Dermofit obejmuje następujące klasy:

- actinic keratosis,
- basal cell carcinoma,
- squamous cell carcinoma,
- seborrheic keratosis,
- malignant melanoma,
- nevus,
- intraepithelial carcinoma,
- pyogenic granuloma,
- haemangioma,
- dermatofibroma.

Na tle innych zbiorów danych Dermofit wyróżnia się obecnością rzadziej spotykanych kategorii zmian skórnych, takich jak rak śródnabłonkowy, ziarniniak naczyński oraz naczyński krwionośny, co zwiększa jego wartość w badaniach nad klasyfikacją wieloklasową (b.d.; Ballerini i in., 2013)

Tabela 3.1. Zestawienie zbiorów zmian skórnych

Nazwa zbioru	Autorzy	Rok publikacji	Dostępność	Metoda zdjęć	Liczba obrazów	Liczba klas	% potwierdzony histopatologicznie	Klasy
HAM10000	(Tischandl, Rosendahl i Kittler, 2018)	2018	Dostępny publicznie	Badanie dermoskopowe	10015	7	53,3%	327 - actinic keratosis 514 - basal cell carcinoma 1.099 - benign keratosis 115 - dermatofibroma 1.113 - melanoma 6705 - nevus 142 - vascular lesion
BCN20000	(Hernández-Pérez i in., 2024)	2024	Dostępny publicznie	Zdjęcia kliniczne, zdjęcia z przybliżeniem, badanie dermoskopowe	18946	8	100%	737 - actinic keratosis 2.809 - basal cell carcinoma 431 - squamous cell carcinoma 1.138 - benign keratosis 124 - dermatofibroma 2.857 - melanoma 4.206 - nevus 111 - vascular lesion
DERM7PT	(Kawahara i in., 2019)	2019	Dostępny publicznie	Zdjęcia kliniczne, badanie dermoskopowe	1011	20	Brak informacji	42 - basal cell carcinoma 1 - melanoma 64 - melanoma in situ 102 - melanoma < 0,76 mm 53 - melanoma 0,76–1,5 mm 28 - melanoma > 1,5 mm 28 - blue/Clark nevus 13 - combined nevus 17 - congenital nevus 33 - dermal nevus 6 - recurrent nevus 79 - reed/spitz nevus 20 - dermatofibroma 24 - lentigo 16 - melanosis 8 - miscellaneous 29 - vascular lesion 45 - seborrheic keratosis
PAD-UFES-20	(Pacheco i in., 2020)	2020	Dostępny publicznie	Zdjęcia kliniczne wykonane smartfonem	2298	6	58,4%	730 - actinic keratosis 845 - basal cell carcinoma 192 - squamous cell carcinoma 52 - melanoma 244 - nevus 235 - seborrheic keratosis
MED-NODE	(Giotis i in., 2015)	2015	Dostępny publicznie	Zdjęcia wykonane aparatem cyfrowym	170	2	Brak informacji	70 - melanoma 100 - nevus
PH2	(Mendonca i in., 2013)	2013	Dostępny publicznie	Badanie dermoskopowe	200	2	20,5%	40 - melanoma 160 - nevus
Fitzpatrick17k	(Groh i in., 2021)	2021	Dostępny publicznie	Zdjęcia wykonane w różnych warunkach, z różnych źródeł	16577	114	Brak informacji	10886 - inflammatory 1.352 - malignant epidermal 1.194 - genodermatoses 1.067 - benign dermal 931 - benign epidermal 573 - malignant melanoma 236 - benign melanocyte 182 - malignant cutaneous lymphoma 156 - malignant dermal
Dermofit	(b.d.; Ballerini i in., 2013)	2013	Wymaga umowy i opłaty	Zdjęcia wykonane aparatem cyfrowym	1300	10	Brak informacji	45 - actinic keratosis 239 - basal cell carcinoma 88 - squamous cell carcinoma 78 - intraepithelial carcinoma 65 - dermatofibroma 76 - melanoma 331 - nevus 24 - pyogenic granuloma 96 - haemangioma 257 - seborrheic keratosis

Źródło: opracowanie własne

3.2 Dobór zbiorów i opis wybranych zmian skórnych

Dostępne zbiory danych obejmują szerokie spektrum jednostek chorobowych, wobec czego opracowanie mobilnego systemu umożliwiającego identyfikację różnych zmian skórnych wymaga starannego doboru źródeł danych oraz ujednolicenia klas przed rozpoczęciem dalszej analizy. Ograniczenie liczby rozpoznawanych typów zmian jest konieczne, ponieważ nadmierna liczba klas zwiększałaby złożoność obliczeniową modelu oraz mogłaby prowadzić do niewystarczającej liczby przykładów dla poszczególnych kategorii. Z kolei zbyt mała liczba klas obniżyłaby użyteczność systemu.

W eksperymentach wykorzystano zbiory HAM10000, BCN20000, DERM7PT, ISIC 2020 oraz PAD-UFES-20. Wstępne próby łączenia zdjęć dermoskopowych ze zdjęciami wykonanymi aparatem telefonu wykazały, że tak duża heterogeniczność danych znacząco obniżała jakość modelu i utrudniała efektywne uczenie się charakterystyk obrazów. W konsekwencji zdecydowano się na wytrenowanie dwóch odrębnych modeli - jednego opartego wyłącznie na obrazach dermoskopowych oraz drugiego trenowanego jedynie na zdjęciach wykonanych aparatem smartfonu.

Model wytrenowany na obrazach dermoskopowych osiągał bardzo wysokie wyniki na danych testowych pochodzących z tego samego typu obrazów, jednak jego skuteczność drastycznie spadała w przypadku zdjęć wykonanych telefonem. Wynika to z faktu, że fotografie mobilne charakteryzują się znacznie większą zmiennością pod względem oświetlenia, jakości oraz sposobu kadrowania. W kolejnym etapie wytrenowano modele wyłącznie na zbiorze PAD-UFES-20. Uzyskane wyniki wskazały, że modele oparte na tym zbiorze radzą sobie najlepiej w warunkach odpowiadających rzeczywistemu zastosowaniu aplikacji mobilnej. Z tego powodu zdecydowano się wykorzystać wyłącznie PAD-UFES-20 jako podstawę dalszych badań.

Analiza zmian skórnych przez system opiera się wyłącznie na obrazie, więc wykorzystano jedynie metadane w postaci odnośników do zdjęć oraz odpowiadających im diagnoz. W zbiorze PAD-UFES-20 wyróżniono sześć kategorii zmian skórnych:

- BCC (basal cell carcinoma) - 845 obrazów raka podstawnokomórkowego,
- ACK (actinic keratosis) - 730 obrazów rogowacenia słonecznego,
- NEV (nevus) - 244 obrazy znamion melanocytowych, czyli pieprzyków,
- SEK (seborrheic keratosis) - 235 obrazów rogowacenia łojotokowego,

- SCC (squamous cell carcinoma) - 192 obrazy raka kolczystkomórkowego,
- MEL (melanoma) - 52 obrazy czerniaka.

3.2.1 Rak podstawnkomórkowy - basal cell carcinoma



Rysunek 3.1. Klasa „basal cell carcinoma”


Źródło: PAD-UFES-20 (Pacheco i in., 2020)

Rak podstawnkomórkowy (basal cell carcinoma, BCC), przedstawiony na Rysunku 3.1 jest najczęściej występującym złośliwym nowotworem skóry, szczególnie u osób o jasnej karnacji. Rozwija się w wyniku przewlekłej ekspozycji na promieniowanie ultrafioletowe oraz częściej dotyczy osób w starszym wieku. Zmiana zwykle wykazuje obecność pajęczek naczyń na swojej powierzchni, a wraz z upływem czasu stopniowo się powiększa, prowadząc do powstania nieregularnej, szorstkiej struktury.

BCC wywodzi się z keratynocytów warstwy podstawnej naskórka, rozwijających się w obrębie skóry uszkodzonej przez działanie promieniowania słonecznego. Charakteryzuje się powolnym wzrostem oraz niskim ryzykiem przerzutów, co sprawia, że rokowanie jest zazwyczaj dobre, zwłaszcza przy wczesnym wykryciu. Standardową metodą leczenia jest chirurgiczne usunięcie zmiany, które w większości przypadków prowadzi do całkowitego wyleczenia (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010).

3.2.2 Rogowacenie słoneczne - actinic keratosis

Klasa rogowacenia słonecznego obejmuje nieinwazyjne zmiany przednowotworowe powstające w wyniku przewlekłej ekspozycji na promieniowanie ultrafioletowe. Zmiana może przekształcić się w złośliwego raka kolczystkomórkowego, przez co wymaga obserwacji. Pojedyncze obszary rogowacenia słonecznego różnią się od siebie i pojawiają się w każdym miejscu przewlekłe eksponowanym na słońce, np. na twarzy, uszach i szyi. Przykładową fotografię rogowacenia słonecznego przedstawiono na Rysunku



Rysunek 3.2. Klasa „actinic keratosis”

Źródło: PAD-UFES-20 (Pacheco i in., 2020)

3.2. Rozpoznanie wymaga potwierdzenia histopatologicznego, natomiast leczenie może obejmować krioterapię, wyłyżeczkowanie lub chirurgiczne usunięcie zmiany (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010).

3.2.3 Zmiana melanocytowa - nevus



Rysunek 3.3. Klasa „nevus”

Źródło: PAD-UFES-20 (Pacheco i in., 2020)

Klasa nevus dotyczy łagodnych znamion melanocytowych, powszechnie określanych jako pieprzyki. Zmiany melanocytowe nie stanowią zagrożenia zdrowotnego, usuwa się je głównie ze względów estetycznych bądź w przypadku podejrzenia zezłośliwienia (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010). Pod względem dermoskopowym mogą znacznie się różnić między sobą, m.in. w zakresie barwy, jednak w przeciwieństwie do czerniaka cechują się symetrią oraz jednorodnością struktury. Przykładowy obraz z klasy NEV przedstawiono na Rysunku 3.3.

3.2.4 Rogowacenie łojotokowe - seborrheic keratosis

Rogowacenie łojotokowe, określane również jako brodawka starcza, to łagodna zmiana nowotworowa wywodząca się z komórek naskórka. Zmiany te są zazwyczaj wyniosłe powierzchnię skóry i mają ostro odgraniczone granice. Wraz z upływem czasu mogą stop-



Rysunek 3.4. Klasa „seborrheic keratosis”

Źródło: PAD-UFES-20 (Pacheco i in., 2020)

niowo powiększać się i ciemnieć. Rogowacenie łojotokowe nie stanowi zagrożenia zdrowotnego i nie ulega zezłośliwieniu, dlatego leczenie nie jest konieczne (Hafner i Vogt, 2008). Przykładową zmianę należącą do klasy SEK przedstawiono na Rysunku 3.4.

3.2.5 Rak kolczystokomórkowy - squamous cell carcinoma



Rysunek 3.5. Klasa „squamous cell carcinoma”

Źródło: PAD-UFES-20 (Pacheco i in., 2020)

Rak kolczystokomórkowy to złośliwy nowotwór skóry rozwijający się najczęściej u osób starszych, szczególnie w miejscach przewlekłe narażonych na działanie czynników karcynogennych, takich jak promieniowanie ultrafioletowe czy związki pochodne dziegciu. Nowotwór ten wywodzi się z keratynocytów warstwy kolczystej naskórka i może klinicznie przypominać rogowacenie słoneczne lub przyjmować postać większych mas bądź owrzodzeń. SCC charakteryzuje się stosunkowo niskim ryzykiem przerzutów, Leczenie opiera się na chirurgicznym wycięciu zmiany, a w wybranych przypadkach stosuje się również radioterapię (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010). Przykład raka kolczystokomórkowego pokazano na Rysunku 3.5.




Rysunek 3.6. Klasa „melanoma”

Źródło: PAD-UFES-20 (Pacheco i in., 2020)

3.2.6 Czerniak - melanoma


Czerniak złośliwy to agresywny nowotwór wywodzący się z znamion melanocytowych, mogący występować zarówno w postaci inwazyjnej i nieinwazyjnej (in situ). Zmianę przedstawiono na Rysunku 3.6. Wczesne wykrycie czerniaka umożliwia skuteczne leczenie chirurgiczne. Czerniak różni się od łagodnych znamion melanocytowych nieregularną strukturą, asymetrią oraz niejednorodnością barwy (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010).



Rysunek 3.7. Rozkład klas w zbiorze po ich ujednoliceniu

Źródło: opracowanie własne

Łącznie badany zbiór obejmował 2.298 obrazów, co przedstawiono na wykresie słupkowym (Rys. 3.7) oraz wykresie kołowym (Rys. 3.8). W kolejnych etapach przeprowadzono dalsze czyszczenie oraz przygotowanie danych pod kątem wymagań modelu, co szczegółowo opisano w Rozdziale 4, w podrozdziale „Obróbka danych”.




Rysunek 3.8. Procentowy udział klas w zbiorze przed ich ujednoliceniem

Źródło: opracowanie własne

3.3 Infrastruktura


Pierwszym etapem opracowania systemu identyfikacji zmian skórnych jest przygotowanie i wytrenowanie odpowiedniego modelu uczenia maszynowego. W ramach niniejszej pracy zastosowano technikę *transfer learning*, polegającą na wykorzystaniu wcześniej wytrenowanych modeli konwolucyjnych i dostosowaniu ich do specyfiki nowych danych. Po zakończeniu procesu uczenia model został skonwertowany do formatu TensorFlow Lite, umożliwiające uruchamianie bezpośrednio na urządzeniach mobilnych z systemem Android, co oznacza, że inferencja odbywa się lokalnie, bez konieczności przesyłania danych do zewnętrznej infrastruktury obliczeniowej. Aplikacja mobilna została opracowana w języku Kotlin z wykorzystaniem biblioteki Jetpack Compose, która umożliwia stworzenie interfejsu użytkownika. Model w formacie TFlite jest integralną częścią aplikacji. Znajduje się on w zasobach programu i jest wykorzystywany bezpośrednio do procesu wnioskowania za pomocą biblioteki TensorFlow Lite, zapewniającej obsługę modeli uczenia maszynowego na urządzeniach mobilnych.



Rysunek 3.9. Uproszczony diagram systemu przedstawiający działanie aplikacji

Źródło: opracowanie własne

Diagram na Rys. 3.9 przedstawia uproszczoną architekturę systemu oraz ścieżkę interakcji użytkownika z aplikacją. W pierwszym kroku użytkownik wykonuje zdjęcie zmiany skórnej za pomocą aparatu telefonu komórkowego lub wczytuje je z pamięci urządzenia.



Rysunek 3.10. Interfejs użytkownika aplikacji

Źródło: opracowanie własne

Następnie obraz jest przekazany do lokalnie przechowywanego modelu TFLite, który dokonuje inferencji i zwraca wynik klasyfikacji, który jest wyświetlony na interfejsie użytkownika w postaci procentowych prawdopodobieństw przynależności badanej zmiany do każdej z klas, co przedstawiono na Rys. 3.10.

3.4 Podsumowanie

Prezentowany system stanowi przykład praktycznego wykorzystania głębokich sieci neuronowych do wstępnego rozpoznawania zmian skórnych, uwzględniający zarówno obecne regulacje prawne, jak i ograniczenia technologii sztucznej inteligencji oraz związane z nią zagadnienia etyczne. Aplikacja wykorzystuje powszechną dostępność smartfonów oraz rosnącą jakość ich aparatów fotograficznych, aby zwiększać świadomość pacjentów w zakresie monitorowania zmian skórnych i wspierać wczesną identyfikację niepokojących objawów. Choć współczesne modele uczenia maszynowego nie osiągnęły jeszcze poziomu dojrzałości umożliwiającego ich pełnoprawne zastosowanie kliniczne, rozwijanie prototypowych rozwiązań tego typu pozostaje kluczowe dla dalszego postępu AI. Systemy wykorzystujące sieci neuronowe mogą w przyszłości asystować lekarzom w procesie diagnostycznym, odciążać służbę zdrowia oraz zwiększać świadomość pacjentów w zakresie wczesnego wykrywania zmian skórnych. Należy podkreślić, że wynik wygenerowany przez model nie stanowi diagnozy medycznej, lecz jedynie statystyczne przybliżenie oparte na ograniczonym zbiorze danych treningowych. W kontekście wyzwań opisanych w Rozdziale 2, obejmujących m.in. stroniczość danych, brak wyjaśnialności wyniku oraz kwestie regulacyjne, które dopiero rozwijają się w dziedzinie sztucznej inteligencji, kliniczne zastosowanie przedstawionego rozwiązania pozostaje znacząco ograniczone.

Wykorzystanie lokalnie działającego modelu, bez konieczności przesyłania zdjęć do chmury, stanowi zaletę pod względem prywatności i bezpieczeństwa danych użytkownika. Jednocześnie jednak takie podejście uniemożliwia dalsze doskonalenie modelu na podstawie rzeczywistych zdjęć wykonywanych przez użytkowników, co mogłoby przyczynić się do zwiększenia jego skuteczności i lepszej generalizacji. Ponadto proponowane rozwiązanie nie eliminuje fundamentalnych ograniczeń technologii głębokiego uczenia, takich jak podatność na błędy wynikające z jakości zdjęcia, różnorodności urządzeń czy brak pełnej interpretowalności decyzji modelu. Z tych względów opracowany system należy traktować jako narzędzie pomocnicze, którego główną rolą jest zwiększanie świadomości użytkownika oraz ułatwianie wczesnej identyfikacji zmian mogących wymagać konsultacji dermatologicznej. Ostateczna decyzja diagnostyczna powinna zawsze należeć do lekarza, a system może jedynie uzupełniać proces podejmowania decyzji, nie zastępując profesjonalnej oceny klinicznej.

Rozdział 4

Metodyka badania

4.1 Model sieci neuronowej

4.1.0.1 Wstęp

Badania przeprowadzono w środowisku Python z wykorzystaniem interaktywnego notatnika Jupyter Notebook. Obliczenia wykonywano na komputerze wyposażonym w kartę graficzną NVIDIA GeForce RTX 5070 Ti, umożliwiającą akcelerację obliczeń w oparciu na technologii CUDA. Wykorzystanie GPU pozwoliło znacząco skrócić czas trenowania modeli konwolucyjnych oraz umożliwiło przeprowadzenie złożonych eksperymentów w rozsądnym czasie obliczeniowym.

Podczas konfiguracji i trenowania sieci neuronowych zastosowano zestaw bibliotek pomagających w przetwarzaniu danych, budowę modeli głębokiego uczenia oraz analizie wyników. Główne pakiety wykorzystane w badaniu to:

- **pandas** - narzędzie do analizy danych tabelarycznych, umożliwiające ich wczytywanie, filtrowanie oraz łączenie metadanych z obrazami (Mckinney, [2011](#)),
- **numpy** - biblioteka numeryczna wykorzystywana do operacji na macierzach, wektorach oraz konwersji obrazów do formatów wejściowych modeli (Harris i in., [2020](#)),
- **matplotlib** oraz **seaborn** – pakiety do wizualizacji danych, używane do generowania wykresów, prezentacji obrazów oraz analizy rozkładów klas (Barrett i in., [2005](#); Waskom, [2021](#)),

- **tensorflow** oraz **keras** - pakiety głębokiego uczenia wykorzystywane do trenowania modeli konwolucyjnych oraz obsługi akceleracji GPU (Abadi i in., 2016),
- **torch** oraz **torchvision** - biblioteki do budowy i trenowania sieci neuronowych, wykorzystywane do transformacji obrazów, przygotowania zbiorów danych oraz korzystania z gotowych architektur modeli (Marcel i Rodriguez, 2010; Paszke i in., 2019),
- **scikit-learn** - zestaw narzędzi do analizy predykcyjnej, umożliwiający podział danych na zbiory treningowe i testowe, obliczanie wag klas oraz ewaluację modeli (Pedregosa i in., 2018),
- **Pillow (PIL)** - biblioteka służąca do podstawowego przetwarzania obrazów, w tym ich wczytywania, skalowania i konwersji.

4.1.1 Obróbka danych

Zbiór PAD-UFES-20 pobrano lokalnie i załadowano z dysku, a następnie rozpakowano archiwa zdjęć, co przedstawiono w fragmencie kodu. W kolejnym kroku utworzono kolumnę path, która wskazywała pełną ścieżkę do konkretnego pliku graficznego. Umożliwiło to późniejsze elastyczne operowanie na obrazach.

```
def unzip(zip_path, extract_to):
    if not os.path.exists(zip_path):
        print(f"ZIP nie istnieje: {zip_path}")
        return
    os.makedirs(extract_to, exist_ok=True)
    with zipfile.ZipFile(zip_path, 'r') as zip_ref:
        zip_ref.extractall(extract_to)
```

Listing 4.1. Funkcja do rozpakowywania archiwów ZIP

Po rozpakowaniu zdjęć przypisano każdemu rekordowi dokładnej lokalizacji odpowiadającego mu obrazu na dysku. Następnie przeprowadzono weryfikację integralności danych polegającą na próbie otwarcia każdego pliku graficznego. Obrazy, które generowały wyjątek, zostały usunięte ze zbioru, co zapewniło poprawność danych wejściowych wykorzystywanych w dalszych etapach analizy.

```
def remove_corrupted(metadata, path_column="path"):
    good, bad = [], []
    for path in metadata[path_column]:
        try:
            if path is None or not os.path.exists(path):
                bad.append(path)
                continue
            img = Image.open(path)
            img.verify()
```


```

good.append(path)
except Exception:
bad.append(path)
return metadata[metadata[path_column].isin(good)].reset_index(drop=True)

```

Listing 4.2. Funkcja do usuwania uszkodzonych obrazów

Ze względu na silną nierównowagę klas zastosowano oversampling, czyli technikę polegającą na sztucznym zwiększeniu liczby przykładów klas rzadkich przez wielokrotne powielanie. W efekcie liczebność kategorii SK, NEV, MEL oraz SCC została zwiększona do 300 przykładów. Rysunek 4.1 przedstawia rozkład klas w zbiorze przed (lewy wykres) oraz po procesie oversampling (prawy wykres).



Rysunek 4.1. Rozkład klas przed i po procesie oversampling

Źródło: opracowanie własne

Następnie wydzielono zbiór treningowy, testowy oraz walidacyjny w proporcjach:

- dane treningowe - 1.998 przykładów (72% zbioru),
- dane walidacyjne - 222 przykładów (8% zbioru),
- dane testowe - 555 przykładów (20% zbioru).

4.1.2 Przygotowanie do trenowania

W celu przygotowania danych do trenowania wykorzystano klasę ImageDataGenerator z biblioteki Keras, która umożliwia wykonywanie losowych transformacji obrazów podczas trenowania modelu. Zastosowana augmentacja danych zwiększa różnorodność próbek treningowych, co ogranicza ryzyko przeuczenia modelu oraz lepiej odzwierciedla naturalną zmienność jakości zdjęć wykonywanych smartfonem. Przeprowadzono trzy ekspe-

rymenty porównawcze, analizujące wpływ różnych konfiguracji augmentacji na skuteczność klasyfikacji. Na podstawie wyników wybrano zestaw umiarkowanych transformacji, obejmujący:

- rotację do 15 stopni,
- przesunięcia poziome i pionowe do 10%,
- przybliżenie do 15%,
- zmiany jasności w zakresie 0,8-1,2,
- uzupełnianie pikseli metodą najbliższego sąsiada.

Wybrane transformacje umożliwiają modelowi uczenie się bardziej odpornych reprezentacji cech, co jest szczególnie istotne w przypadku obrazów pozyskiwanych w warunkach domowych, przy zmiennym oświetleniu oraz różnorodnej jakości aparatów mobilnych. Dla zbiorów walidacyjnych i testowych zastosowano generatory bez augmentacji, aby zapewnić obiektywną i powtarzalną ocenę jakości modelu.

```
train_datagen = ImageDataGenerator(1
    preprocessing_function=preprocess_input,2
    rotation_range=15,3
    width_shift_range=0.1,4
    height_shift_range=0.1,5
    zoom_range=0.15,6
    horizontal_flip=True,7
    vertical_flip=True,8
    brightness_range=[0.8, 1.2],9
    fill_mode='nearest'10
)1112131415
```

Listing 4.3. Definicja ImageDataGenerator dla klasy treningowej

W celu dodatkowego zwiększenia różnorodności danych treningowych oraz poprawy uogólniania modelu zastosowano technikę mixup wprowadzoną przez H. Zhang i in. (2018). Polega ona na generowaniu nowych próbek treningowych przez tworzenie liniowych kombinacji dwóch losowo dobranych obrazów oraz odpowiadających im etykiet. Mixup wprowadza do danych ciągłość, co sprzyja uczeniu bardziej stabilnych funkcji decyzyjnych oraz redukuje tendencję modelu do zapamiętywania pojedynczych przykładów.

Funkcja mixup dla każdej partii danych losuje współczynnik λ z rozkładu $\beta(\alpha, \alpha)$, gdzie α domyślnie ustawiono na 0,4.

```
def mixup(batch_x, batch_y, alpha=0.4):1
```

```

lam = np.random.beta(alpha, alpha)
idx = np.random.permutation(len(batch_x))
mixed_x = lam * batch_x + (1 - lam) * batch_x[idx]
mixed_y = lam * batch_y + (1 - lam) * batch_y[idx]
return mixed_x, mixed_y

```

Listing 4.4. Implementacja funkcji mixup

Współczynnik λ określa proporcję, w jakiej są łączone dwa obrazy oraz odpowiadające im etykiety. Losowa permutacja idx zapewnia, że każda próbka ze zbioru jest mieszana z inną, niezależnie dobranej obserwacją (H. Zhang i in., 2018). Nowe dane treningowe powstają przez liniową interpolację:

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j. \quad (4.1)$$

Aby umożliwić stosowanie funkcji mixup w sposób ciągły podczas trenowania danych, przygotowano generator mixup, który opakowuje standardowy generator z biblioteki Keras. Pobiera on partie z innego generatora, stosuje transformacje mixup i przekazuje w wyniku zmodyfikowane próbki.

```

def mixup_generator(base_gen, alpha=0.4):
    while True:
        batch_x, batch_y = next(base_gen)
        mixed_x, mixed_y = mixup(batch_x, batch_y, alpha)
        yield mixed_x, mixed_y

```

Listing 4.5. Generator Mixup

Następnie zdefiniowano generator treningowy, odpowiedzialny za wczytywanie obrazów oraz augmentację obrazu, a w kolejnym kroku wzbogacono go o mixup. Generatory walidacyjne i testowe pozostawiono bez augmentacji i mixup, aby zapewnić obiektywną ocenę jakości modelu (Thulasidasan i in., 2020).

W celu porównania skuteczności różnych architektur konwolucyjnych sieci neuronowych zdefiniowano słownik modeli dostępnych w ramach biblioteki Keras. Każdy z modeli został wykorzystany jako feature extractor w podejściu transfer learning z wejściem o wymiarach 299 x 299 x 3. Wybór architektur obejmuje zarówno modele lekkie, zoptymalizowane pod kątem urządzeń mobilnych, jak i głębokie sieci o wysokiej dokładności, co umożliwia porównanie kompromisu między złożonością obliczeniową a skutecznością klasyfikacji.

- MobileNetV2 - model zoptymalizowany pod kątem urządzeń mobilnych, oparty na liniowych wąskich gardłach, oraz odwróconych blokach resztowych (Sandler i in., 2019),

- MobileNetV3Large - ulepszona wersja MobileNet, przeznaczona do zastosowań wymagających wyższej precyzji (Howard i in., [2019](#)),
- ResNet50 - 50-warstwowa sieć neuronowa oparta na blokach resztkowych, rozwiązujących problem zanikającego gradientu (K. He i in., [2015](#)),
- ResNet101 - głębsza wersja ResNet, zawierająca 101 warstw konwolucyjnych (K. He i in., [2015](#)),
- EfficientNetB0 - (Tan i Le, [2020](#)),
- DenseNet121 - 121-warstwowa konwolucyjna sieć neuronowa, która łączy wyjście każdej warstwy z wejściem kolejnych warstw (Huang i in., [2018](#)),
- ConvNeXtTiny - model nowej generacji inspirowany architekturą Transformer (Liu i in., [2022](#)).

4.1.3 Proces trenowania

Aby umożliwić elastyczne trenowanie wielu modeli, stworzono wysokopoziomowy moduł TransferLearningTuner, który kompleksowo obsługuje cały proces trenowania z wykorzystaniem techniki transfer learning. Konstruktor klasy przyjmuje między innymi nazwę modelu bazowego zdefiniowaną w słowniku, liczbę klas, generatory danych oraz parametry trenowania.

TransferLearningTuner w pierwszym kroku tworzy bazową architekturę, wczytując wybrany model i zamrażając jego wagi, co zapobiega degradacji wcześniej wyuczonych reprezentacji. W kolejnym kroku dodaje warstwy klasyfikacyjne, które redukują wymiar cech, stabilizują trenowanie oraz zapobiegają przeuczeniu.


Pierwszy etap trenowania polega na uczeniu wyłącznie warstw klasyfikacyjnych przy zamrożonych wagach modelu bazowego. Domyślnie trenowanie w tym etapie składa się z pięciu epok. Do trenowania wykorzystano optymalizator Adam oraz funkcję straty CategoricalCrossentropy, która redukuje wpływ klas dominujących na predykcje modelu (Kingma i Ba, [2017](#); Z. Zhang i Sabuncu, [2018](#)). Zdefiniowano również kilka funkcji wywoływanych po każdej epoce lub po zakończeniu procesu, polegających na zapisie najlepszych wag modelu, zatrzymaniu trenowania po trzech epokach bez poprawy oraz redukcji learning rate, czyli współczynnika określającego czułość na błędy.

Drugi etap trenowania odmraża większość warstw modelu bazowego z wyjątkiem warstw BatchNormalization, które przechowują statystyki domenowe i ich trenowanie

mogłoby destabilizować proces (Ioffe i Szegedy, 2015; Kanavati i Tsuneki, 2021). Odmro-
żenie warstw pozwala dostosować głębsze reprezentacje do specyfiki danych dermato-
logicznych.

Po zakończeniu trenowania jest wykonywana ewaluacja na zbiorze testowym a na-
stępnie generowana jest macierz pomyłek, wynik F1 dla każdej klasy oraz wykresy strat
i dokładności. Wytrenowany model jest konwertowany do formatu TensorFlow Lite,
umożliwiając wykorzystanie go do bezpośredniej inferencji na urządzeniu mobilnym.
Cały przepływ jest uruchamiany metodą run, która wykonuje oba etapy trenowania oraz
pełną ewaluację.

4.2 Aplikacja mobilna



Rysunek 4.2. Diagram klas przedstawiający działanie aplikacji

Źródło: opracowanie własne

W ramach utworzenia prototypu systemu zaprojektowano aplikację mobilną wykorzystującą wytrenowany model klasyfikacji zmian skórnych. Aplikację zaimplementowano na platformę Android z użyciem języka Kotlin oraz biblioteki Jetpack Compose, która umożliwia deklaratywne tworzenie interfejsu użytkownika. Model sieci neuronowej został umieszczony w zasobach aplikacji i obsługiwany za pomocą biblioteki TensorFlow Lite.


Diagram 4.2 przedstawia pełną architekturę aplikacji, w której warstwa interfejsu użytkownika jest oddzielona od logiki przetwarzania obrazu oraz inferencji modelu. Głównym punktem wejścia aplikacji jest klasa `MainActivity`, odpowiedzialna za inicjalizację środowiska Jetpack Compose. Klasa ta korzysta z `MainViewModel`, który zarządza stanem aplikacji.

Po stronie interfejsu użytkownika kluczową rolę pełni komponent `AppLayout`, tworzony w ramach `MainActivity`. Odpowiada on za ogólny układ aplikacji, w tym wyświetlanie górnego i dolnego paska nawigacyjnego (`TopAppBar` oraz `BottomAppBar`) oraz za inicjalizację głównego obszaru roboczego. `AppLayout` tworzy komponent `ScreenContent`, który decyduje o tym, jaki ekran zostanie wyświetlony - ekran klasyfikacji (`PredictionScreen`) lub ekran informacyjny (`InfoScreen`), zależnie od stanu `showInfo` przechowywanego w `MainViewModel`.

Ekran `PredictionScreen` odpowiada za wyświetlanie instrukcji oraz wyników klasyfikacji. Jeżeli użytkownik nie wykonał jeszcze zdjęcia, `PredictionScreen` prezentuje komunikat z instrukcją dotyczącą wykonania fotografii zmiany skórnej. Po wykonaniu zdjęcia i przetworzeniu go przez model wywoływany jest komponent `AnalysisPanel`, który generuje dynamiczną listę elementów `PredictionRow`. Każdy z nich reprezentuje pojedynczy wynik inferencji, zawierający typ zmiany skórnej oraz poziom pewności klasyfikacji. Ekran `InfoScreen` pełni funkcję informacyjną. Zawiera zestaw bloków `LesionInfoBlock`, prezentujących opisy wszystkich typów zmian skórnych zdefiniowanych w enumeracji `LesionType` oraz informacje na temat projektu.


Logika przetwarzania obrazu oraz komunikacja z modelem TensorFlow Lite została umieszczona w dedykowanej klasie `TFLiteHelper`. Klasa ta jest tworzona i przechowywana wewnątrz `MainViewModel`, co zapewnia jej spójny cykl życia. `TFLiteHelper` odpowiada za przygotowanie danych wejściowych, w tym skalowanie obrazu, konwersję do formatu `ByteBuffer` oraz zastosowanie preprocessingu zgodnego z architekturą

modelu. Wynik inferencji stanowi wektor prawdopodobieństw, który jest mapowany na typy zmian skórnych zdefiniowane w `LesionType`. Każdy wynik jest reprezentowany jako obiekt `PredictionResult`.



Rysunek 4.3. Diagram klas przedstawiający przepływ użytkownika przez proces klasyfikacji zmiany skórnej

Źródło: opracowanie własne




Rysunek 4.4. Diagram klas przedstawiający InfoScreen

Źródło: opracowanie własne

Przepływ danych w aplikacji odzwierciedla naturalny scenariusz użytkownika. Proces rozpoczyna się od wykonania zdjęcia lub wyboru obrazu z galerii. `MainViewModel` aktualizuje stan `imageBitmap`, a następnie wywołuje metodę `predict()` w klasie `TFLiteHelper`. Otrzymane wyniki są przekazywane do warstwy prezentacji i wyświetlane w komponencie `PredictionScreen` w postaci listy obiektów `PredictionResult`. Użytkownik może również przełączyć się do zakładki Info, w której komponent `InfoScreen` prezentuje szczegółowe opisy wszystkich typów zmian skórnych. Pełen przepływ użytkownika wraz z prezentacją interfejsu przedstawiono na Rysunkach 4.3 oraz 4.4.

4.3 Wyniki modeli




Rysunek 4.5. Wykres przedstawiający wyniki badanych modeli

Źródło: opracowanie własne

Wyniki uzyskane przez modele zagregowano na wykresie słupkowym (Rys. 4.5) oraz na mapie cieplnej (Rys. 4.6).

4.3.1 Metryki

Analiza metryk uzyskanych przez poszczególne architektury przedstawiona na (Rys. 4.5) oraz (Rys. 4.6) ujawnia wyraźne różnice w ich skuteczności w zadaniu klasyfikacji zdjęć telefonem komórkowych zmian skórnych. Najwyższą jakość predykcji osiągnęły modele z rodziny ResNet. ResNet50 oraz ResNet101 uzyskały odpowiednio średni F1-score równy




Rysunek 4.6. Mapa cieplna przedstawiająca wyniki badanych modeli

Źródło: opracowanie własne

0,72 i 0,714, co czyni je zdecydowanie najlepszymi spośród wszystkich testowanych modeli. Obie sieci osiągnęły również najwyższe wartości AUC powyżej 0,9, co świadczy o ich wysokiej zdolności rozróżniania klas. Dokładność dla ResNet50 wyniosła 0,741, a dla ResNet101 0,768. Modele ConvNeXtTiny oraz MobileNetV3Large osiągnęły umiarkowane wyniki z dokładnością na poziomie odpowiednio 0,589 i 0,566, AUC w wysokości 0,852 i 0,856 oraz średnim wynikiem F1 0,5676 oraz 0,498. EfficientNetB0, DenseNet121 oraz MobileNetV2 uzyskały najniższe wyniki w badaniu. Dokładność EfficientNetB0 na badanym zbiorze danych wyniosła 0,535, a dla pozostałych modeli była poniżej 50%. Niskie wyniki lekkich wersji architektur zoptymalizowanej pod kątem urządzeń mobilnych, świadczą o tym, że nie są one w stanie uchwycić złożonych wzorców teksturalnych i strukturalnych charakterystycznych dla obrazów dermatologicznych.

4.3.2 Wartości F1 dla poszczególnych klas

Wygenerowano również raport (Rys. 4.7) przedstawiający wartości F1-score dla każdego modelu w podziale na analizowane klasy zmian skórnych. W przypadku klasy rogowacenia słonecznego (ACK) najwyższe wyniki uzyskały modele z rodziny ResNet, co potwierdza wysoką zdolność do rozpoznawania zmian przednowotworowych. Architektury mobilne osiągnęły znacznie niższe wartości F1, co sugeruje, że ich ograniczona głębokość



Rysunek 4.7. Mapa cieplna przedstawiająca F1-score dla wszystkich modeli

Źródło: opracowanie własne

oraz mniejsza liczba parametrów nie pozwalają na uchwycenie subtelnych cech rogowacenia słonecznego. Modele ConvNeXtTiny oraz EfficientNetB0 uzyskały wyniki umiarkowane, plasując się między modelami mobilnymi a wersjami architektury rezyduальной.

Wszystkie modele poradziły sobie stosunkowo dobrze z klasyfikacją raka podstawno-komórkowego skóry (BCC), co może wynikać z jego największej reprezentacji w zbiorze danych. Najwyższe wartości F1 osiągnęły ResNet50 oraz ResNet101, natomiast architektury mobilne uzyskały wyniki w zakresie 0,45-0,57. DenseNet121 osiągnął w tej klasie swój najlepszy rezultat z F1 na poziomie 0,613.

Czerniak (MEL) stanowi klasę o kluczowym znaczeniu klinicznym i jednocześnie jedną z najtrudniejszych do klasyfikacji ze względu na duże podobieństwo do łagodnych znamion melanocytowych. Dodatkowym utrudnieniem jest fakt, że MEL był najmniej liczny w zbiorze i jego liczebność była sztucznie zwiększona procesem oversampling. Najwyższe wyniki osiągnęły modele ResNet101 i ResNet50, oba z F1 równym 0,917, co potwierdza ich zdolność do uchwycenia złożonych, nieregularnych wzorców charakterystycznych dla czerniaka. Bardzo dobry wynik uzyskał również ConvNeXtTiny (0,760). Najstabilniej pora-

dził sobie MobileNetV2, co całkowicie dyskwalifikuje go jako kandydata do zastosowań w aplikacjach mających pomagać pacjentom w rozpoznawaniu zmian skórnych.

Znamiona melanocytowe (NEV) były najlepiej klasyfikowane przez modele z rodziny ResNet, które osiągnęły najwyższe wartości F1. Umiarkowane wyniki uzyskały MobileNetV3Large oraz ConvNeXtTiny, natomiast najniższy wynik ponownie odnotowano dla MobileNetV2, co potwierdza jego ograniczoną zdolność do rozróżniania zmian o dużej zmienności wewnątrzklasowej.

Największe trudności wiązały się z klasyfikacją raka kolczystokomórkowego (SCC). Szczególnie słabo wypadł DenseNet121, który uzyskał F1 równe 0, co wskazuje na całkowity brak zdolności do poprawnej klasyfikacji tej klasy. Trudność ta może wynikać z klinicznego podobieństwa SCC do rogowacenia słonecznego, z którego często się rozwija, a także z faktu, że SCC charakteryzuje się objawami, których nie da się w pełni uchwycić na zdjęciach, takimi jak podrażnienie, ból czy uniesienie brzegów przewlekłego owrzodzenia (Bourke, Graham-Brown i red. wyd. pol. Andrzej Kaszuba, 2010). Modele ResNet uzyskały najwyższe, choć nadal umiarkowane wyniki (0,511-0,564).

Klasa obejmująca łagodne rogowacenie łojotokowe (SEK) również charakteryzowała się stosunkowo niskimi wynikami F1 w porównaniu z innymi kategoriami. Najlepsze rezultaty uzyskały ResNet101 (0,698) oraz ResNet50 (0,718). Najsłabszy wynik ponownie osiągnął MobileNetV2 (0,069), natomiast pozostałe architektury uzyskały wartości F1 w zakresie 0,333-0,471.

4.3.3 Podsumowanie wyników

Przeprowadzone eksperymenty wykazały wyraźne różnice skuteczności między analizowanymi wersjami architektury. Najwyższą jakości predykcji uzyskały modele z rodziny ResNet, które osiągnęły najlepsze wyniki we wszystkich kluczowych metrykach. ResNet101 i ResNet50 wykazały się zarówno najwyższą skutecznością ogólną jak i największą stabilnością między klasami, co potwierdzają wysokie wartości F1 dla większości zmian skórnych, w tym klas trudnych diagnostycznie, takich jak czerniak i rak kolczystokomórkowy. Model ConvNeXtTiny, czyli nowoczesna architektura inspirowana Transformerami, osiągnął wyniki wyraźnie lepsze niż wszystkie sieci mobilne oraz DenseNet121. ConvNeXtTiny okazał się szczególnie skuteczny w klasach MEL, NEV i ACK. Modele mobilne - MobileNetV2, MobileNetV3Large oraz EfficientNetB0 - uzyskały wyraźnie niższe

wyniki. Ograniczona liczba parametrów i uproszczona architektura sprawiają, że modele nie są w stanie uchwycić złożonych wzorców charakterystycznych dla zmian skórnych. Najłabiej wypadł MobileNetV2, natomiast MobileNetV3Large oraz EfficientNetB0 uzyskały umiarkowane wyniki, jednak nadal były one znacznie gorsze od rezultatów ResNet oraz ConvNeXtTiny. DenseNet121, który w literaturze jest często wykorzystywany do zadań medycznych, osiągnął słabe wyniki, wykazując niestabilność między klasami. Może to wynikać z wysokiej wrażliwości na hiperparametry oraz podatność na przeuczenie w przypadku zbiorów o dużej zmienności wewnątrzklasowej (Huang i in., 2018).

4.4 Praktyczne zastosowanie aplikacji

Wybór modelu do aplikacji mobilnej wykonującej inferencję bezpośrednio na urządzeniu wymaga uwzględnienia zarówno skuteczności diagnostycznej, kosztu obliczeniowego, obejmującego czas przetwarzania, zużycie energii oraz opóźnienie inferencji. W oparciu o uzyskane wyniki, obejmujące wysoką skuteczność ogólną, stabilność między klasami oraz dobrą wydajność, do systemu wdrożono architekturę ResNet101. Model został przetestowany po konwersji do formatu TFLite pod kątem złożoności obliczeniowej oraz czasu inferencji na dwóch urządzeniach - Samsung Galaxy A35 oraz Google Pixel 8a, oba z Androidem w wersji 16.

Aplikacja mobilna osiąga wnioskowanie w czasie niemal rzeczywistym, co potwierdza możliwość praktycznego zastosowania modelu w warunkach mobilnych, bez konieczności korzystania z infrastruktury serwerowej. Przeprowadzono również około dziesięciu testów empirycznych na dwóch pacjentach polegających na fotografowaniu rzeczywistych zmian skórnych za pomocą aplikacji oraz analizie wyników klasyfikacji, aby ocenić zachowanie modelu w warunkach zbliżonych do użytkowania przez pacjentów. Badane zmiany stanowiły łagodne znamiona, których charakter został potwierdzony przez dermatologa w standardowym badaniu dermoskopowym w ciągu ostatnich trzech miesięcy. Zdjęcia wykonywano w naturalnym oświetleniu, z wykorzystaniem dziesięciokrotnego przybliżenia. W przeprowadzonych testach aplikacja przewidywała łagodność zmian z pewnością przekraczającą 85%, co potwierdza wysoką skuteczność modelu w praktycznym scenariuszu użytkowym. Uzyskane wyniki przedstawiono na Rysunku 4.8.



Rysunek 4.8. Przykładowe wyniki badań empirycznych znamion łagodnych

Źródło: opracowanie własne

Pomimo obiecujących rezultatów, pełna walidacja systemu wymaga przeprowadzenia rozszerzonych badań obejmujących pozostałe klasy zmian skórnych, w szczególności te rzadziej występujące oraz trudniejsze diagnostycznie. Dalsza ocena powinna być realizowana pod nadzorem dermatologa, co pozwoli na zweryfikowanie skuteczności apli-

kacji w warunkach klinicznych oraz określenie jej potencjalnych ograniczeń i kierunków dalszej optymalizacji.

4.5 Podsumowanie

Metodyka badania objęła wybór oraz przygotowanie danych, proces trenowania modeli głębokiego uczenia metodą *transfer learning*, analizę uzyskanych wyników oraz implementację i wstępną walidację aplikacji mobilnej służącej do klasyfikacji zmian skórnych. Szczegółowo opisano procedurę przygotowania zbioru, obejmującą standaryzację obrazów, podział na zbiory treningowy, walidacyjny i testowy oraz zastosowane techniki augmentacji, w tym klasyczne transformacje obrazu oraz metodę mixup. Przedstawiono proces trenowania siedmiu architektur konwolucyjnych kompleksowym przetwarzaniem TransferLearningTuner. Analiza wyników wykazała wyraźną przewagę modeli z rodziny ResNet, które osiągnęły najwyższe wartości kluczowych metryk - dokładności, AUC oraz wynik F1 dla klas. ResNet101 oraz ResNet50 okazały się najbardziej stabilne między klasami, szczególnie w przypadku kategorii trudnych diagnostycznie, takich jak czerniak (MEL) oraz rak kolczystokomórkowy (SCC). Na podstawie przeprowadzonej analizy wybrano model ResNet101 do wdrożenia w aplikacji mobilnej, którą zaimplementowano w języku Kotlin. Wybrany model przekonwertowano do formatu TensorFlow Lite w celu inferencji na urządzeniu. Przeprowadzono testy empiryczne na rzeczywistych zdjęciach łagodnych zmian skórnych wykonanych aparatem telefonu, których łagodny charakter został przewidziany ze skutecznością 85%.

Rozdział 5

Podsumowanie

W niniejszej pracy podjęto tematykę dynamicznie rozwijających się technologii sztucznej inteligencji w kontekście diagnostyki zmian skórnych. Przedstawiono potencjał konwolucyjnych sieci neuronowych w obszarze *computer-aided diagnosis*, jednocześnie zwracając uwagę na istniejące ograniczenia, takie jak ramy etyczne i regulacyjne, kwestie poufności oraz bezpieczeństwa danych pacjentów, brak wyjaśnialności decyzji oraz brak niezależnych i reprezentatywnych zbiorów danych. Zauważono również rosnącą rolę urządzeń mobilnych jako narzędzi wspierających pacjentów w monitorowaniu zmian skórnych oraz zwiększaniu świadomości dotyczącej wczesnej diagnostyki.

W pracy przeanalizowano aktualną literaturę dotyczącą zastosowania konwolucyjnych sieci neuronowych w medycynie, ze szczególnym uwzględnieniem diagnostyki dermatologicznej, oraz omówiono istniejące rozwiązania mobilne w tej dziedzinie. Zaproponowano autorski system obejmujący model *pre-trained* przekonwertowany do formatu TensorFlow Lite oraz aplikację mobilną na system Android, wykonującą inferencję bezpośrednio na urządzeniu pacjenta. Przedstawiono dostępne repozytoria i zbiory zmian skórnych, ich charakterystykę oraz luki, które wypełniają w kontekście badań nad sztuczną inteligencją w dermatologii.

Po przeprowadzeniu eksperymentów na różnych zestawach danych ostatecznie zdecydowano się wykorzystać zbiór PAD-UFES-20, zawierający zdjęcia wykonane aparatem telefonu komórkowego, co stanowiło przedmiot dalszych badań i zapewniło wysoką skuteczność pomimo zmienności obrazów. W procesie trenowania zastosowano technikę *transfer learning*, polegającą na dostosowaniu wcześniej wytrenowanego modelu do specyfiki nowych danych oraz zestaw metod augmentacji obrazu, w tym mixup, zwięks-

szających zdolność uogólniania modeli. Zbadano skuteczność siedmiu wersji architektury konwolucyjnej. Najlepsze wyniki osiągnął model ResNet101, uzyskując AUC równy 0,938 oraz dokładność na poziomie 0,768 w zbiorze testowym. Model ten został wykorzystany w implementacji aplikacji mobilnej. Skuteczność aplikacji oceniono w ramach wstępnych testów empirycznych przeprowadzonych na niewielkiej próbie łagodnych zmian skórnych, których charakter został potwierdzony przez dermatologa. Wyniki te potwierdziły poprawność działania systemu w warunkach zbliżonych do rzeczywistego użytkowania.

Kolejnym etapem badań powinno być rozszerzenie testów empirycznych o rzadsze i złośliwe zmiany skórne, przeprowadzane pod nadzorem dermatologa. W przyszłości aplikację można również rozszerzyć o obsługę innych systemów operacyjnych, ponieważ obecnie funkcjonuje wyłącznie na urządzeniach z systemem Android. Istotnym kierunkiem rozwoju jest także implementacja funkcjonalności umożliwiającej monitorowanie zmian w czasie, co stanowi ważny element diagnostyki dermatologicznej, a jednocześnie nie zawsze jest możliwe w warunkach klinicznych.

Ograniczeniem obecnej wersji systemu jest wykorzystywanie wyłącznie danych obrazowych. Uwzględnienie dodatkowych informacji, takich jak wiek, płeć, lokalizacja zmiany czy obecność bólu lub świądu, mogłoby znacząco zwiększyć skuteczność diagnostyczną, szczególnie w przypadku raka kolczystokomórkowego. Kolejną wadą jest brak możliwości porównania danej zmiany z pozostałymi znamionami pacjenta, co uniemożliwia zastosowanie zasady „brzydkiego kaczątka”, powszechnie wykorzystywanej przez dermatologów.

Mimo tych ograniczeń, zaprezentowany system wykazuje znaczący potencjał w obszarze diagnostyki cyfrowej. Dostępność narzędzia na urządzeniach mobilnych może realnie zwiększać świadomość pacjentów dotyczącą wyglądu potencjalnie złośliwych zmian skórnych. Tworzenie tego typu prototypów jest szczególnie istotne w kontekście dynamicznego rozwoju technologii sztucznej inteligencji oraz kształtujących się ram regulacyjnych. Systemy takie mogą w przyszłości przyczynić się do poprawy wczesnej diagnostyki nowotworów skóry na całym świecie, zwłaszcza w regionach o ograniczonym dostępie do specjalistycznej opieki dermatologicznej.

Bibliografia

- (b.d.). <https://licensing.edinburgh-innovations.ed.ac.uk/product/dermofit-image-library>
- Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., Devin, M., Ghemawat, S., Irving, G., Isard, M., Kudlur, M., Levenberg, J., Monga, R., Moore, S., Murray, D. G., Steiner, B., Tucker, P., Vasudevan, V., Warden, P., Wicke, M., Yu, Y., Zheng, X. (2016). TensorFlow: A system for large-scale machine learning. <https://arxiv.org/abs/1605.08695>
- Abbasi, N. R., Shaw, H. M., Rigel, D. S., Friedman, R. J., McCarthy, W. H., Osman, I., Kopf, A. W., Polsky, D. (2004). Early Diagnosis of Cutaneous Melanoma: Revisiting the ABCD Criteria. *JAMA*, 292(22), 2771. <https://doi.org/10.1001/jama.292.22.2771>
- Adegun, A. A., Viriri, S. (2020). Deep Learning-Based System for Automatic Melanoma Detection. *IEEE Access*, 8, 7160–7172. <https://doi.org/10.1109/ACCESS.2019.2962812>
- Ali, S., Abuhmed, T., El-Sappagh, S., Muhammad, K., Alonso-Moral, J. M., Confalonieri, R., Guidotti, R., Del Ser, J., Díaz-Rodríguez, N., Herrera, F. (2023). Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence. *Information Fusion*, 99, 101805. <https://doi.org/10.1016/j.inffus.2023.101805>
- Alonso, S. G., De La Torre Díez, I., Zapiraín, B. G. (2019). Predictive, Personalized, Preventive and Participatory (4P) Medicine Applied to Telemedicine and eHealth in the Literature. *Journal of Medical Systems*, 43(5), 140. <https://doi.org/10.1007/s10916-019-1279-4>
- Al-rimy, B. A. S., Saeed, F., Al-Sarem, M., Albarrak, A. M., Qasem, S. N. (2023). An Adaptive Early Stopping Technique for DenseNet169-Based Knee Osteoarthritis

- Detection Model. *Diagnostics*, 13(11), 1903. <https://doi.org/10.3390/diagnostics13111903>
- Alwakid, G., Gouda, W., Humayun, M., Sama, N. U. (2022). Melanoma Detection Using Deep Learning-Based Classifications. *Healthcare*, 10(12), 2481. <https://doi.org/10.3390/healthcare10122481>
- Alzubaidi, L., Al-Amidie, M., Al-Asadi, A., Humaidi, A. J., Al-Shamma, O., Fadhel, M. A., Zhang, J., Santamaría, J., Duan, Y. (2021). Novel Transfer Learning Approach for Medical Imaging with Limited Labeled Data. *Cancers*, 13(7), 1590. <https://doi.org/10.3390/cancers13071590>
- Amisha, Malik, P., Pathania, M., Rathaur, V. (2019). Overview of artificial intelligence in medicine. *Journal of Family Medicine and Primary Care*, 8(7), 2328. https://doi.org/10.4103/jfmpc.jfmpc_440_19
- Ballerini, L., Fisher, R., Aldridge, B., Rees, J. (2013, styczeń). A Color and Texture Based Hierarchical K-NN Approach to the Classification of Non-melanoma Skin Lesions. https://doi.org/10.1007/978-94-007-5389-1_4
- Barrett, P., Hunter, J., Miller, J., Hsu, J.-C., Greenfield, P. (2005). matplotlib – A Portable Python Plotting Package.
- Bassel, A., Abdulkareem, A. B., Alyasseri, Z. A. A., Sani, N. S., Mohammed, H. J. (2022). Automatic Malignant and Benign Skin Cancer Classification Using a Hybrid Deep Learning Approach. *Diagnostics*, 12(10). <https://doi.org/10.3390/diagnostics12102472>
- Bourke, J., Graham-Brown, R., red. wyd. pol. Andrzej Kaszuba. (2010). *Dermatologia. Podręcznik i atlas*. Elsevier Urban & Partner.
- Bourouis, A., Zerdazi, A., Feham, M., Bouchachia, A. (2013a). M-Health: Skin Disease Analysis System Using Smartphone's Camera [The 4th International Conference on Ambient Systems, Networks and Technologies (ANT 2013), the 3rd International Conference on Sustainable Energy Information Technology (SEIT-2013)]. *Procedia Computer Science*, 19, 1116–1120. <https://doi.org/https://doi.org/10.1016/j.procs.2013.06.157>
- Bourouis, A., Zerdazi, A., Feham, M., Bouchachia, A. (2013b). M-Health: Skin Disease Analysis System Using Smartphone's Camera. *Procedia Computer Science*, 19, 1116–1120. <https://doi.org/10.1016/j.procs.2013.06.157>

- Bowman, P. H., Hogan, D. J., Sanusi, I. (2001). Mycosis fungoides bullosa: Report of a case and review of the literature. *Journal of the American Academy of Dermatology*, 45(6), 934–939. <https://doi.org/10.1067/mjd.2001.117521>
- Brewer, A. C., Endly, D. C., Henley, J., Amir, M., Sampson, B. P., Moreau, J. F., Dellavalle, R. P. (2013). Mobile Applications in Dermatology. *JAMA Dermatology*, 149(11), 1300–1304. <https://doi.org/10.1001/jamadermatol.2013.5517>
- Briganti, G., Le Moine, O. (2020). Artificial Intelligence in Medicine: Today and Tomorrow. *Frontiers in Medicine*, 7, 27. <https://doi.org/10.3389/fmed.2020.00027>
- Brinker, T. J., Hekler, A., Enk, A. H., Klode, J., Hauschild, A., Berking, C., Schilling, B., Haferkamp, S., Schadendorf, D., Holland-Letz, T., Utikal, J. S., von Kalle, C., Ludwig-Peitsch, W., Sirokay, J., Heinzerling, L., Albrecht, M., Baratella, K., Bischof, L., Chorti, E., Dith, A., Drusio, C., Giese, N., Gratsias, E., Griewank, K., Hallasch, S., Hanhart, Z., Herz, S., Hohaus, K., Jansen, P., Jockenhöfer, F., Kanaki, T., Knispel, S., Leonhard, K., Martaki, A., Matei, L., Matull, J., Olischewski, A., Petri, M., Placke, J.-M., Raub, S., Salva, K., Schlott, S., Sody, E., Steingrube, N., Stoffels, I., Ugurel, S., Zaremba, A., Gebhardt, C., Booken, N., Christolouka, M., Buder-Bakhaya, K., Bokor-Billmann, T., Enk, A., Gholam, P., Hänßle, H., Salzmann, M., Schäfer, S., Schäkel, K., Schank, T., Böhne, A.-S., Deffaa, S., Drerup, K., Egberts, F., Erkens, A.-S., Ewald, B., Falkvoll, S., Gerdes, S., Harde, V., Hauschild, A., Jost, M., Kosova, K., Messinger, L., Metzner, M., Morrison, K., Motamedi, R., Pinczker, A., Rosenthal, A., Scheller, N., Schwarz, T., Stölzl, D., Thielking, F., Tomaschewski, E., Wehkamp, U., Weichenthal, M., Wiedow, O., Bär, C. M., Bender-Säbelkamp, S., Horbrügger, M., Karoglan, A., Kraas, L., Faulhaber, J., Geraud, C., Guo, Z., Koch, P., Linke, M., Maurier, N., Müller, V., Thomas, B., Utikal, J. S., ... Schröder, P. (2019). Deep learning outperformed 136 of 157 dermatologists in a head-to-head dermoscopic melanoma image classification task. *European Journal of Cancer*, 113, 47–54. <https://doi.org/https://doi.org/10.1016/j.ejca.2019.04.001>
- Chapman, T., Larsson, E., von Wrycza, P., Dahlman, E., Parkvall, S., Sköld, J. (2015). Chapter 1 - From 3G to 4G: background and motivation of 3G evolution. W T. Chapman, E. Larsson, P. von Wrycza, E. Dahlman, S. Parkvall J. Sköld (Red.), *HSPA Evolution* (s. 3–20). Academic Press. <https://doi.org/https://doi.org/10.1016/B978-0-08-099969-2.00001-6>

- Congdon, N. M., Davis, C. M. (2023). A systematic review of the frequency of features of the seven-point checklist in proven cutaneous melanoma: The importance of change. *Skin Health and Disease*, 3(6), e295. <https://doi.org/10.1002/ski2.295>
- Dai, X., Spasić, I., Meyer, B., Chapman, S., Andres, F. (2019). Machine Learning on Mobile: An On-device Inference App for Skin Cancer Detection. *2019 Fourth International Conference on Fog and Mobile Edge Computing (FMEC)*, 301–305. <https://doi.org/10.1109/FMEC.2019.8795362>
- Das, N., Happaerts, S., Gyselinck, I., Staes, M., Derom, E., Brusselle, G., Burgos, F., Contoli, M., Dinh-Xuan, A. T., Franssen, F. M., Gonem, S., Greening, N., Haenebalcke, C., Man, W. D.-C., Moisés, J., Peché, R., Poberezhets, V., Quint, J. K., Steiner, M. C., Vanderhelst, E., Abdo, M., Topalovic, M., Janssens, W. (2023). Collaboration between explainable artificial intelligence and pulmonologists improves the accuracy of pulmonary function test interpretation. *European Respiratory Journal*, 61(5), 2201720. <https://doi.org/10.1183/13993003.01720-2022>
- Davis, S., Piggott, C., Lyon, C., DeSanto, K. (2020). Effectiveness of dermoscopy in skin cancer diagnosis. *Canadian Family Physician Medecin De Famille Canadien*, 66(10), 739–740.
- Duarte, A. F., Sousa-Pinto, B., Azevedo, L. F., Barros, A. M., Puig, S., Malveyh, J., Haneke, E., Correia, O. (2021). Clinical ABCDE rule for early melanoma detection. *European Journal of Dermatology*, 31(6), 771–778. <https://doi.org/10.1684/ejd.2021.4171>
- Elyan, E., Vuttipittayamongkol, P., Johnston, P., Martin, K., McPherson, K., Moreno-García, C. F., Jayne, C., Sarker, M. M. K. (2022). Computer vision and machine learning for medical image analysis: recent advances, challenges, and way forward. *Artificial Intelligence Surgery*, 2(1). <https://doi.org/10.20517/ais.2021.15>
- Erickson, B. J., Kitamura, F. (2021). Magician’s Corner: 9. Performance Metrics for Machine Learning Models. *Radiology: Artificial Intelligence*, 3(3), e200126. <https://doi.org/10.1148/ryai.2021200126>
- Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118. <https://doi.org/10.1038/nature21056>

- Farhud, D. D., Zokaei, S. (2021). Ethical Issues of Artificial Intelligence in Medicine and Healthcare. *Iranian Journal of Public Health*, 50(11), i–v. <https://doi.org/10.18502/ijph.v50i11.7600>
- Ghosh, A., Sufian, A., Sultana, F., Chakrabarti, A., De, D. (2020, styczeń). Fundamental Concepts of Convolutional Neural Network. https://doi.org/10.1007/978-3-030-32644-9_36
- Giotis, I., Molders, N., Land, S., Biehl, M., Jonkman, M. F., Petkov, N. (2015). MED-NODE: A computer-assisted melanoma diagnosis system using non-dermoscopic images. *Expert systems with applications*, 42(19), 6578–6585.
- Głos, A. (2017). MEDYCYNĄ P4 I ANTYNOMIE SAMOWIEDZY. *Filozofia w Praktyce*, Tom 3(Artykuł 6).
- Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning* [[http : / / www . deeplearningbook.org](http://www.deeplearningbook.org)]. MIT Press.
- Grandini, M., Bagli, E., Visani, G. (2020). Metrics for Multi-Class Classification: an Overview. <https://doi.org/10.48550/ARXIV.2008.05756>
- Grob, J. J., Bonerandi, J. J. (1998). The ‘Ugly Duckling’ Sign: Identification of the Common Characteristics of Nevi in an Individual as a Basis for Melanoma Screening. *Archives of Dermatology*, 134(1), 103. <https://doi.org/10.1001/archderm.134.1.103-a>
- Groh, M., Harris, C., Soenksen, L., Lau, F., Han, R., Kim, A., Koochek, A., Badri, O. (2021). Evaluating deep neural networks trained on clinical images in dermatology with the fitzpatrick 17k dataset. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 1820–1828.
- Gutkowicz-Krusin, D., Elbaum, M., Jacobs, A., Keem, S., Kopf, A. W., Kamino, H., Wang, S., Rubin, P., Rabinovitz, H., Oliviero, M. (2000). Precision of automatic measurements of pigmented skin lesion parameters with a MelaFindTM multispectral digital dermoscope: *Melanoma Research*, 10(6), 563–570. <https://doi.org/10.1097/00008390-200012000-00008>
- Hafner, C., Vogt, T. (2008). Seborrheic keratosis. *JDDG: Journal der Deutschen Dermatologischen Gesellschaft*, 6(8), 664–677. <https://doi.org/10.1111/j.1610-0387.2008.06788.x>

- Halcox, J. P., Wareham, K., Cardew, A., Gilmore, M., Barry, J. P., Phillips, C., Gravenor, M. B. (2017). Assessment of Remote Heart Rhythm Sampling Using the AliveCor Heart Monitor to Screen for Atrial Fibrillation: The REHEARSE-AF Study. *Circulation*, 136(19), 1784–1794. <https://doi.org/10.1161/CIRCULATIONAHA.117.030583>
- Haleem, A., Javaid, M., Singh, R. P., Rab, S., Suman, R. (2023). Applications of nano-technology in medical field: a brief review. *Global Health Journal*, 7(2), 70–77. <https://doi.org/https://doi.org/10.1016/j.glohj.2023.02.008>
- Han, S. S., Kim, M. S., Lim, W., Park, G. H., Park, I., Chang, S. E. (2018). Classification of the Clinical Images for Benign and Malignant Cutaneous Tumors Using a Deep Learning Algorithm. *Journal of Investigative Dermatology*, 138(7), 1529–1538. <https://doi.org/10.1016/j.jid.2018.01.028>
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., Gérard-Marchant, P., Sheppard, K., Reddy, T., Weckesser, W., Abbasi, H., Gohlke, C., Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. <https://doi.org/10.1038/s41586-020-2649-2>
- He, J., Baxter, S. L., Xu, J., Xu, J., Zhou, X., Zhang, K. (2019). The practical implementation of artificial intelligence technologies in medicine. *Nature Medicine*, 25(1), 30–36. <https://doi.org/10.1038/s41591-018-0307-0>
- He, K., Zhang, X., Ren, S., Sun, J. (2015). Deep Residual Learning for Image Recognition. <https://arxiv.org/abs/1512.03385>
- Henning, J. S., Stein, J. A., Yeung, J., Dusza, S. W., Marghoob, A. A., Rabinovitz, H. S., Polsky, D., Kopf, A. W. (2008). CASH Algorithm for Dermoscopy Revisited. *Archives of Dermatology*, 144(4). <https://doi.org/10.1001/archderm.144.4.554>
- Hernández-Pérez, C., Combalia, M., Podlipnik, S., Codella, N. C. F., Rotemberg, V., Halpern, A. C., Reiter, O., Carrera, C., Barreiro, A., Helba, B., Puig, S., Vilaplana, V., Malvehy, J. (2024). BCN20000: Dermoscopic Lesions in the Wild. *Scientific Data*, 11(1), 641. <https://doi.org/10.1038/s41597-024-03387-w>

- Hinton, G., Krizhevsky, A., Sutskever, I., Rachmad, Y. (2012). ImageNet Classification with Deep Convolutional Neural Networks. *Advances in Neural Information Processing Systems*, 1097–1105. <https://doi.org/10.1145/3065386>
- Hosseinzadeh Kassani, S., Hosseinzadeh Kassani, P. (2019). A comparative study of deep learning architectures on melanoma detection. *Tissue and Cell*, 58, 76–83. <https://doi.org/10.1016/j.tice.2019.04.009>
- Howard, A., Sandler, M., Chu, G., Chen, L.-C., Chen, B., Tan, M., Wang, W., Zhu, Y., Pang, R., Vasudevan, V., Le, Q. V., Adam, H. (2019). Searching for MobileNetV3. <https://arxiv.org/abs/1905.02244>
- Huang, G., Liu, Z., van der Maaten, L., Weinberger, K. Q. (2018). Densely Connected Convolutional Networks. <https://arxiv.org/abs/1608.06993>
- Hubel, D. H., Wiesel, T. N. (1968). Receptive fields and functional architecture of monkey striate cortex. *The Journal of Physiology*, 195(1), 215–243. <https://doi.org/10.1113/jphysiol.1968.sp008455>
- Hussain, E., Hasan, M., Rahman, M. A., Lee, I., Tamanna, T., Parvez, M. Z. (2021). Co-roDet: A deep learning based classification for COVID-19 detection using chest X-ray images. *Chaos, Solitons & Fractals*, 142, 110495. <https://doi.org/10.1016/j.chaos.2020.110495>
- Ioffe, S., Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. <https://arxiv.org/abs/1502.03167>
- Ismael, A. M., Şengür, A. (2021). Deep learning approaches for COVID-19 detection based on chest X-ray images. *Expert Systems with Applications*, 164, 114054. <https://doi.org/10.1016/j.eswa.2020.114054>
- Jojoa Acosta, M. F., Caballero Tovar, L. Y., Garcia-Zapirain, M. B., Percybrooks, W. S. (2021). Melanoma diagnosis using deep learning techniques on dermatoscopic images. *BMC Medical Imaging*, 21(1), 6. <https://doi.org/10.1186/s12880-020-00534-8>
- Kamińska-Winciorek, G., Śpiewak, R. (2011). [Basic dermoscopy of melanocytic lesions for beginners]. *Postępy higieny i medycyny doświadczalnej (Online)*, 65, 501–8. <https://doi.org/10.5604/17322693.955121>

- Kanavati, F., Tsuneki, M. (2021). Partial transfusion: on the expressive influence of trainable batch norm parameters for transfer learning. <https://arxiv.org/abs/2102.05543>
- Karthik, R., Menaka, R., Johnson, A., Anand, S. (2020). Neuroimaging and deep learning for brain stroke detection - A review of recent advancements and future prospects. *Computer Methods and Programs in Biomedicine*, 197, 105728. <https://doi.org/https://doi.org/10.1016/j.cmpb.2020.105728>
- Kawahara, J., Bentaieb, A., Hamarneh, G. (2016). Deep features to classify skin lesions, 1397–1400. <https://doi.org/10.1109/ISBI.2016.7493528>
- Kawahara, J., Daneshvar, S., Argenziano, G., Hamarneh, G. (2019). Seven-Point Checklist and Skin Lesion Classification Using Multitask Multimodal Neural Nets. *IEEE Journal of Biomedical and Health Informatics*, 23(2), 538–546. <https://doi.org/10.1109/JBHI.2018.2824327>
- Kelly, C. J., Karthikesalingam, A., Suleyman, M., Corrado, G., King, D. (2019). Key challenges for delivering clinical impact with artificial intelligence. *BMC Medicine*, 17(1), 195. <https://doi.org/10.1186/s12916-019-1426-2>
- Kingma, D. P., Ba, J. (2017). Adam: A Method for Stochastic Optimization. <https://arxiv.org/abs/1412.6980>
- Kong, F. W., Horsham, C., Ngoo, A., Soyer, H. P., Janda, M. (2021). Review of smartphone mobile applications for skin cancer detection: what are the changes in availability, functionality, and costs to users over time? *International Journal of Dermatology*, 60(3), 289–308. <https://doi.org/10.1111/ijd.15132>
- Kousis, I., Perikos, I., Hatzilygeroudis, I., Virvou, M. (2022). Deep Learning Methods for Accurate Skin Cancer Recognition and Mobile Application. *Electronics*, 11(9), 1294. <https://doi.org/10.3390/electronics11091294>
- LeCun, Y., Bengio, Y., Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Lee, K. H., Lee, R. W., Kwon, Y. E. (2023). Validation of a Deep Learning Chest X-ray Interpretation Model: Integrating Large-Scale AI and Large Language Models for Comparative Analysis with ChatGPT. *Diagnostics*, 14(1), 90. <https://doi.org/10.3390/diagnostics14010090>

- Li, Z., Koban, K. C., Schenck, T. L., Giunta, R. E., Li, Q., Sun, Y. (2022). Artificial Intelligence in Dermatology Image Analysis: Current Developments and Future Trends. *Journal of Clinical Medicine*, 11(22), 6826. <https://doi.org/10.3390/jcm11226826>
- Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., Xie, S. (2022). A ConvNet for the 2020s. <https://arxiv.org/abs/2201.03545>
- Lu, X., Firoozeh Abolhasani Zadeh, Y. A. (2022). Deep Learning-Based Classification for Melanoma Detection Using XceptionNet (S. Jafarzadeh Ghouschi, Red.). *Journal of Healthcare Engineering*, 2022, 1–10. <https://doi.org/10.1155/2022/2196096>
- Mackie, R. M. (1990). Clinical recognition of early invasive malignant melanoma. *BMJ (Clinical research ed.)*, 301(6759), 1005–1006. <https://doi.org/10.1136/bmj.301.6759.1005>
- Mackie, R. M. (1989). *Malignant melanoma: a guide to early diagnosis*. Duphar Laboratories.
- Mahara, G., Tian, C., Xu, X., Wang, W. (2023). Revolutionising health care: Exploring the latest advances in medical sciences. *Journal of Global Health*, 13, 03042. <https://doi.org/10.7189/jogh.13.03042>
- Mahbod, A., Schaefer, G., Wang, C., Dorffner, G., Ecker, R., Ellinger, I. (2020). Transfer learning using a multi-scale and multi-network ensemble for skin lesion classification. *Computer Methods and Programs in Biomedicine*, 193, 105475. <https://doi.org/10.1016/j.cmpb.2020.105475>
- Marcel, S., Rodriguez, Y. (2010). Torchvision the machine-vision package of torch. *Proceedings of the 18th ACM International Conference on Multimedia*, 1485–1488. <https://doi.org/10.1145/1873951.1874254>
- Mckinney, W. (2011). pandas: a Foundational Python Library for Data Analysis and Statistics. *Python High Performance Science Computer*.
- Mendonca, T., Ferreira, P. M., Marques, J. S., Marcal, A. R. S., Rozeira, J. (2013). PH2 - A dermoscopic image database for research and benchmarking. *2013 35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, 5437–5440. <https://doi.org/10.1109/EMBC.2013.6610779>

- Menegola, A., Fornaciali, M., Pires, R., Bittencourt, F. V., Avila, S., Valle, E. (2017). Knowledge Transfer for Melanoma Screening with Deep Learning [arXiv:1703.07479], (arXiv:1703.07479). <https://doi.org/10.48550/arXiv.1703.07479>
- Menzies, S. W., Ingvar, C., Crotty, K. A., McCarthy, W. H. (1996). Frequency and morphologic characteristics of invasive melanomas lacking specific surface microscopic features. *Archives of Dermatology*, 132(10), 1178–1182.
- Nachbar, F., Stolz, W., Merkle, T., Cognetta, A. B., Vogt, T., Landthaler, M., Bilek, P., Braun-Falco, O., Plewig, G. (1994). The ABCD rule of dermatoscopy. *Journal of the American Academy of Dermatology*, 30(4), 551–559. [https://doi.org/10.1016/S0190-9622\(94\)70061-3](https://doi.org/10.1016/S0190-9622(94)70061-3)
- Naeem, A., Farooq, M. S., Khelifi, A., Abid, A. (2020). Malignant Melanoma Classification Using Deep Learning: Datasets, Performance Measurements, Challenges and Opportunities. *IEEE Access*, 8, 110575–110597. <https://doi.org/10.1109/ACCESS.2020.3001507>
- Nayak, S., Kumar Das, R. (2020, listopad). Application of Artificial Intelligence (AI) in Prosthetic and Orthotic Rehabilitation. W V. Sezer, S. Öncü P. Boyraz Baykas (Red.), *Service Robotics*. IntechOpen. <https://doi.org/10.5772/intechopen.93903>
- of Computer Science, D., Engineering, O., Ladoke Akintola University of Technology, O. Emuoyibofarhe, J., Ajisafe, D. (2020). Early Skin Cancer Detection Using Deep Convolutional Neural Networks on Mobile Smartphone. *International Journal of Information Engineering and Electronic Business*, 12(2), 21–27. <https://doi.org/10.5815/ijieeb.2020.02.04>
- Pacheco, A. G., Lima, G. R., Salomão, A. S., Krohling, B., Biral, I. P., De Angelo, G. G., Alves Jr, F. C., Esgario, J. G., Simora, A. C., Castro, P. B., Rodrigues, F. B., Frasson, P. H., Krohling, R. A., Knidel, H., Santos, M. C., Do Espírito Santo, R. B., Macedo, T. L., Canuto, T. R., De Barros, L. F. (2020). PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones. *Data in Brief*, 32, 106221. <https://doi.org/10.1016/j.dib.2020.106221>
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., Chintala, S. (2019).

- PyTorch: An Imperative Style, High-Performance Deep Learning Library. <https://arxiv.org/abs/1912.01703>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Müller, A., Nothman, J., Louppe, G., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., Duchesnay, É. (2018). Scikit-learn: Machine Learning in Python. <https://arxiv.org/abs/1201.0490>
- Podstawy uczenia maszynowego.* (2022). Wydawnictwa AGH.
- Rainio, O., Teuho, J., Klén, R. (2024). Evaluation metrics and statistical tests for machine learning. *Scientific Reports*, 14(1), 6086. <https://doi.org/10.1038/s41598-024-56706-x>
- Rajaraman, S., Antani, S. K., Poostchi, M., Silamut, K., Hossain, M. A., Maude, R. J., Jager, S., Thoma, G. R. (2018). Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images. *PeerJ*, 6, e4568. <https://doi.org/10.7717/peerj.4568>
- Rajaraman, S., Candemir, S., Kim, I., Thoma, G., Antani, S. (2018). Visualization and Interpretation of Convolutional Neural Network Predictions in Detecting Pneumonia in Pediatric Chest Radiographs. *Applied Sciences (Basel, Switzerland)*, 8(10), 1715. <https://doi.org/10.3390/app8101715>
- Richens, J. G., Buchard, A. (2021). Artificial Intelligence for Medical Diagnosis. W N. Lidströmer H. Ashrafian (Red.), *Artificial Intelligence in Medicine* (s. 1–21). Springer International Publishing. https://doi.org/10.1007/978-3-030-58080-3_29-1
- Rogers, T., Marino, M., Dusza, S. W., Bajaj, S., Marchetti, M. A., Marghoob, A. (2017). Triage amalgamated dermoscopic algorithm (TADA) for skin cancer screening. *Dermatology Practical & Conceptual*, 7(2), 39–46. <https://doi.org/10.5826/dpc.0702a09>
- Rosendahl, C., Cameron, A., McColl, I., Wilkinson, D. (2012). Dermatoscopy in routine practice - “chaos and clues”. *Australian Family Physician*, 41(7), 482–487.
- Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych (RODO) [General Data

- Protection Regulation (GDPR)]. (2016). <https://eur-lex.europa.eu/eli/reg/2016/679/oj>
- Rozporządzenie Parlamentu Europejskiego i Rady (UE) 2024/1689 z dnia 13 czerwca 2024 r. ustanawiające zharmonizowane przepisy dotyczące sztucznej inteligencji (Akt o sztucznej inteligencji) [Artificial Intelligence Act (AI Act)]. (2024). <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>
- Russell, S. J., Norvig, P. (2022). *Artificial intelligence: a modern approach* (Fourth edition, global edition). Pearson.
- Rutkowski, P., J. Wysocki, P., Nasierowska-Guttmejer, A., Fijuth, J., Kalinka-Warzocha, E., Świtaj, T., Jeziorski, A., Szacht, M., Zegarski, W., Wysocki, W. M., Rudnicka, L., Owczarek, W., Krzakowski, M. (2016). Cutaneous melanoma – guidelines for diagnostics and therapy in 2016. *Dermatology Review*, 1, 1–18. <https://doi.org/10.5114/dr.2016.57736>
- Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., Chen, L.-C. (2019). MobileNetV2: Inverted Residuals and Linear Bottlenecks. <https://arxiv.org/abs/1801.04381>
- Schneider, J. W., Dittmer, D. P. (2017). Diagnosis and Treatment of Kaposi Sarcoma. *American Journal of Clinical Dermatology*, 18(4), 529–539. <https://doi.org/10.1007/s40257-017-0270-4>
- Sonthalia, S., Yumeen, S., Kaliyadan, F. (2025). Dermoscopy Overview and Extradiagnostic Applications. W *StatPearls*. StatPearls Publishing. <http://www.ncbi.nlm.nih.gov/books/NBK537131/>
- Sun, W., Zheng, B., Qian, W. (2016). Computer aided lung cancer diagnosis with deep learning algorithms. W G. D. Tourassi S. G. A. III (Red.), *Medical Imaging 2016: Computer-Aided Diagnosis* (97850Z, T. 9785). SPIE. <https://doi.org/10.1117/12.2216307>
- Tan, M., Le, Q. V. (2020). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. <https://arxiv.org/abs/1905.11946>
- Tang, L., Li, J., Fantus, S. (2023). Medical artificial intelligence ethics: A systematic review of empirical studies. *DIGITAL HEALTH*, 9, 20552076231186064. <https://doi.org/10.1177/20552076231186064>
- Thacharodi, A., Singh, P., Meenatchi, R., Tawfeeq Ahmed, Z. H., Kumar, R. R. S., V, N., Kavish, S., Maqbool, M., Hassan, S. (2024). Revolutionizing healthcare and medi-

- cine: The impact of modern technologies for a healthier future—A comprehensive review. *Health Care Science*, 3(5), 329–349. <https://doi.org/10.1002/hcs2.115>
- Thulasidasan, S., Chennupati, G., Bilmes, J., Bhattacharya, T., Michalak, S. (2020). On Mixup Training: Improved Calibration and Predictive Uncertainty for Deep Neural Networks. <https://arxiv.org/abs/1905.11001>
- Topalovic, M., Das, N., Burgel, P.-R., Daenen, M., Derom, E., Haenebalcke, C., Janssen, R., Kerstjens, H. A., Liistro, G., Louis, R., Ninane, V., Pison, C., Schlessers, M., Vercauter, P., Vogelmeier, C. F., Wouters, E., Wynants, J., Janssens, W. (2019). Artificial intelligence outperforms pulmonologists in the interpretation of pulmonary function tests. *European Respiratory Journal*, 53(4), 1801660. <https://doi.org/10.1183/13993003.01660-2018>
- Tschandl, P., Rosendahl, C., Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5(1), 180161. <https://doi.org/10.1038/sdata.2018.161>
- Van Kolschooten, H., Van Oirschot, J. (2024). The EU Artificial Intelligence Act (2024): Implications for healthcare. *Health Policy*, 149, 105152. <https://doi.org/10.1016/j.healthpol.2024.105152>
- Walter, F. M., Prevost, A. T., Vasconcelos, J., Hall, P. N., Burrows, N. P., Morris, H. C., Kinmonth, A. L., Emery, J. D. (2013). Using the 7-point checklist as a diagnostic aid for pigmented skin lesions in general practice: a diagnostic validation study. *The British Journal of General Practice: The Journal of the Royal College of General Practitioners*, 63(610), e345–353. <https://doi.org/10.3399/bjgp13X667213>
- Ward-Peterson, M., Acuña, J. M., Alkhalifah, M. K., Nasiri, A. M., Al-Akeel, E. S., Alkhaldi, T. M., Dawari, S. A., Aldaham, S. A. (2016). Association Between Race/Ethnicity and Survival of Melanoma Patients in the United States Over 3 Decades: A Secondary Analysis of SEER Data. *Medicine*, 95(17), e3315. <https://doi.org/10.1097/MD.0000000000003315>
- Waskom, M. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6, 3021. <https://doi.org/10.21105/joss.03021>
- Weingast, J., Scheibböck, C., Wurm, E. M., Ranharter, E., Porkert, S., Dreiseitl, S., Posch, C., Binder, M. (2013). A Prospective Study of Mobile Phones for Dermatology in

- a Clinical Setting. *Journal of Telemedicine and Telecare*, 19(4), 213–218. <https://doi.org/10.1177/1357633x13490890>
- Wibowo, A., Adhi Hartanto, C., Wisnu Wirawan, P. (2020). Android skin cancer detection and classification based on MobileNet v2 model. *International Journal of Advances in Intelligent Informatics*, 6(2), 135. <https://doi.org/10.26555/ijain.v6i2.492>
- Yang, Y. J., Bang, C. S. (2019). Application of artificial intelligence in gastroenterology. *World Journal of Gastroenterology*, 25(14), 1666–1683. <https://doi.org/10.3748/wjg.v25.i14.1666>
- Yélamos, O., Braun, R. P., Liopyris, K., Wolner, Z. J., Kerl, K., Gerami, P., Marghoob, A. A. (2019). Usefulness of dermoscopy to improve the clinical and histopathologic diagnosis of skin cancers. *Journal of the American Academy of Dermatology*, 80(2), 365–377. <https://doi.org/10.1016/j.jaad.2018.07.072>
- Zhang, H., Cisse, M., Dauphin, Y. N., Lopez-Paz, D. (2018). mixup: Beyond Empirical Risk Minimization. <https://arxiv.org/abs/1710.09412>
- Zhang, Z., Sabuncu, M. R. (2018). Generalized Cross Entropy Loss for Training Deep Neural Networks with Noisy Labels. <https://arxiv.org/abs/1805.07836>

Spis tabel

2.1	Algorytm ABCD	6
3.1	Zestawienie zbiorów zmian skórnych	29

Spis rysunków

2.1	Relacje między sztuczną inteligencją, uczeniem maszynowym i głębokim uczeniem	9
2.2	Podstawowa architektura konwolucyjnej sieci neuronowej	10
3.1	Klasa „basal cell carcinoma”	31
3.2	Klasa „actinic keratosis”	32
3.3	Klasa „nevus”	32
3.4	Klasa „seborrheic keratosis”	33
3.5	Klasa „squamous cell carcinoma”	33
3.6	Klasa „melanoma”	34
3.7	Rozkład klas w zbiorze po ich ujednoliceniu	34
3.8	Procentowy udział klas w zbiorze przed ich ujednoliceniem	35
3.9	Uproszczony diagram systemu przedstawiający działanie aplikacji	36
3.10	Interfejs użytkownika aplikacji	36
4.1	Rozkład klas przed i po procesie oversampling	40
4.2	Diagram klas przedstawiający działanie aplikacji	44
4.3	Diagram klas przedstawiający przepływ użytkownika przez proces klasyfikacji zmiany skórnej	46
4.4	Diagram klas przedstawiający InfoScreen	46
4.5	Wykres przedstawiający wyniki badanych modeli	47
4.6	Mapa cieplna przedstawiająca wyniki badanych modeli	48
4.7	Mapa cieplna przedstawiająca F1-score dla wszystkich modeli	49
4.8	Przykładowe wyniki badań empirycznych znamion łagodnych	52

Spis kodów źródłowych

4.1	Funkcja do rozpakowywania archiwów ZIP	39
4.2	Funkcja do usuwania uszkodzonych obrazów	39
4.3	Definicja ImageDataGenerator dla klasy treningowej	41
4.4	Implementacja funkcji mixup	41
4.5	Generator Mixup	42